

多分辨率融合输入的U型视网膜血管分割算法

梁礼明 詹涛 雷坤 冯骏 谭卢敏*

(江西理工大学电气工程与自动化学院 赣州 341000)

摘 要: 针对视网膜血管拓扑结构不规则、形态复杂和尺度变化多样的特点, 该文提出一种多分辨率融合输入的U型网络(MFIU-Net), 旨在实现视网膜血管精准分割。设计以多分辨率融合输入为主干的粗略分割网络, 生成高分辨率特征。采用改进的ResNeSt代替传统卷积, 优化血管分割边界特征; 将并行空间激活模块嵌入其中, 捕获更多的语义和空间信息。构架另一U型精细分割网络, 提高模型的微观表示和识别能力。一是底层采用多尺度密集特征金字塔模块提取血管的多尺度特征信息。二是利用特征自适应模块增强粗、细网络之间的特征融合, 抑制不相关的背景噪声。三是设计面向细节的双重损失函数融合, 以引导网络专注于学习特征。在眼底数据用于血管提取的数字视网膜图像(DRIVE)、视网膜结构分析(STARE)和儿童心脏与健康研究(CHASE_DB1)上进行实验, 其准确率分别为97.00%, 97.47%和97.48%, 灵敏度分别为82.73%, 82.86%和83.24%, 曲线下的面积(AUC)值分别为98.74%, 98.90%和98.93%。其模型整体性能优于现有算法。

关键词: 视网膜血管分割; U型网络; 并行空间激活模块; 多尺度密集特征金字塔模块; 双重损失函数融合

中图分类号: R318; TP391

文献标识码: A

文章编号: 1009-5896(2023)05-1795-12

DOI: 10.11999/JEIT220470

Multi-resolution Fusion Input U-shaped Retinal Vessel Segmentation Algorithm

LIANG Liming ZHAN Tao LEI Kun FENG Jun TAN Lumin

(School of Electrical Engineering Automation, Jiangxi University of Science and Technology,
Ganzhou 341000, China)

Abstract: Considering the characteristics of irregular retinal blood vessel topology, complex morphology and diverse scale changes, a Multi-resolution Fusion Input U-Netword (MFIU-Net) is proposed to achieve accurate segmentation of retinal blood vessels. A rough segmentation network based on multi-resolution fusion input is designed to generate high-resolution features.. The improved ResNeSt is used to replace the traditional convolution to optimize the boundary features of blood vessel segmentation, and the parallel spatial activation module is embedded to capture more semantic and spatial information. Another U-shaped fine segmentation network is constructed to improve the microscopic representation and recognition ability of the model. Firstly, the multi-scale dense feature pyramid module to extract the multi-scale feature information of blood vessels is adopted at the bottom layer. Secondly, the feature adaptive module is used to enhance the feature fusion between coarse and fine networks to suppress irrelevant background noise. Thirdly, a detail-oriented double loss function fusion is designed to guide the network to focus on learning features. Experiments are carried out on the fundus data Digital Retinal Images for Vessel Extraction (DRIVE), STructured Analysis of the REtinal (STARE) and Child Heart and Health Study (CHASE_DB1), the accuracy rates are 97.00%, 97.47% and 97.48%, the sensitivity is 82.73%, 82.86% and 83.24%, and the Area Under Cure (AUC) values are 98.74%, 98.90% and 98.93%, respectively. The overall performance of its model is better than that of existing algorithms.

收稿日期: 2022-04-18; 改回日期: 2022-07-13; 网络出版: 2022-07-19

*通信作者: 谭卢敏 gztlm2017@163.com

基金项目: 国家自然科学基金(51365017, 61463018), 江西省自然科学基金面上项目(20192BAB205084), 江西省教育厅科学技术研究重点项目(GJJ170491)

Foundation Items: The National Natural Science Foundation of China (51365017, 61463018), The General Project of Jiangxi Provincial Natural Science Foundation (20192BAB205084), The Science and Technology Research Key Project, Department of Education, Jiangxi Province (GJJ170491)

Key words: Retinal vessel segmentation; U-shaped network; Parallel space activation module; Multiscale dense feature pyramid module; Double loss function fusion

1 引言

视网膜血管的形态学变化与青光眼、糖尿病、多种眼科和心血管疾病等密切相关^[1]。因此,视网膜血管的形态结构是许多疾病的重要评价标准。临床医生通过血管的直径和曲率变化实现疾病的诊断、筛查和治疗^[2]。由于血管图像体积小、分支重叠、变形,以及低对比度和噪声干扰,难以实现准确分割。所以,为了解决这些问题,有必要设计出一种准确分割血管的方法,提高临床诊断效率。

现有的分割方法分为两大类:无监督方法和有监督方法。无监督方法不使用任何注释作为参考,旨在根据血管的1个或多个特征提取血管信息。Khawaja等人^[3]提高多尺度检测器的能力,针对细小血管检测。为了减轻渗出物和其他明亮区域的影响,Khawaja等人^[4]使用改进的弗兰吉(Frangi)滤波器和概率补丁降噪器,提高Frangi滤波器的性能。有监督方法需要参考手动注释的样本来构建模型。田丰等人^[5]利用多尺度框架融合轮廓特征和细节特征,进一步保留了血管的细小分支。文献[6]利用2维卡洛南-洛伊(Karhunen-Loeve, K-L)变换对图像进行预处理,并利用多尺度滤波提取血管特征。有监督算法需要依赖手动注释的血管图像,鲁棒性较差,并且没有学习能力。随着神经网络的发展,在医学图像处理领域取得了良好的效果。因此,基于深度学习的算法在视网膜血管分割得到重视与应用。Yang等人^[7]引入可变形卷积构建特征提取模块,增强模型对血管变形的建模能力。Chen等人^[8]利用残差非局部注意网络捕获输入之间的非局部上下文依赖关系,以提取多尺度血管特征。Wang等人^[9]提出一种新的端到端视网膜血管分割深度学习体系结构,设计3个解码器对细小血管和边界不确定的血管进行分析。Zhang等人^[10]将递归神经网络与卷积神经网络相结合,有效地利用血管的上下文特征信息。

虽然以上提出的方法均致力于分割血管并获得较好的效果,但所涉方法通常存在以下问题:(1)模型的下采样因子过大,导致大量细小血管的特征信息在提取中丢失;(2)模型的感受野过小,导致对局部上下文信息理解不足,无法准确区分病理和血管区域;(3)特征提取能力不足,难以保持高分辨层次的详细特征信息,产生大量噪声;(4)无法获得不同形态血管的准确信息,导致血管边界和细小血管检测不准确。

针对视网膜血管分割存在的问题,本文提出一种多分辨率融合输入的U型网络(Multi-resolution Fusion Input U-Network, MFIU-Net)。在原有U-Net的编码基础上,增加额外的多分辨率融合输入分支来保持高分辨率表示,使血管的空间预测图更加精确。整个网络分为粗略分割网络和精细分割网络两部分,通过两个不同的网络分别对血管特征信息进行两次提取,并通过特征自适应模块对粗、细网络相应层的特征映射信息进行融合,以实现多任务同时学习,有效提高血管分割质量。

2 相关工作

2.1 网络总体架构

本文采用双边网络对视网膜血管进行分割:一个是粗略分割网络,另一个是精细分割网络,创造性地设计出多分辨率融合输入结构,提出MFIU-Net分割模型,其网络总体架构如图1所示。粗略网络中含有1条高分辨主干路和2条低分辨率干路。图像首先被送入高分辨主干路的粗略网络中,多分辨架构对其进行处理,逐步融合生成3个不同分辨率的特征图。利用并行空间激活模块将不同分辨率的特征信息进行多次融合,使高分辨主干路能接收到不同低分辨率干路中的特征信息,从而形成更丰富的高分辨率特征表示。再将3张不同分辨率的特征图像输入到精细U型部分进一步提取特征。为了弥补粗略网络在下采样丢失的多尺度特征信息,在底层增加多尺度密集特征金字塔模块,增大感受野提取多尺度特征信息。解码器部分通过上采样逐步恢复分割图像,受文献[11]的启发,上采样的每一步都引入自适应特征模块与粗略网络的不同分辨率跳过拼接,以自适应地匹配粗、精网络特征映射之间的分布,同时抑制不相关的背景噪声干扰。最后经过 1×1 卷积和归一化指数函数(Softmax)运算得到分割结果。受文献[12]的启发,采用改进的拆分注意力网络(Split-attention Networks, ResNeSt)替代传统卷积更好地提取复杂血管的特征信息,缓解梯度爆炸和消失问题,减少血管细小特征和边界轮廓特征的分割丢失,提升网络对特征的提取能力。

2.2 改进的ResNeSt模块

ResNeSt^[13]结合深度神经网络的聚合残差变换(aggregated Residual transformations for deep Neural networks, ResNeXt)^[14]与挤压和激励网络(Squeeze and Excitation Networks, SE-Net)^[15],对通道自适应重新校准并进行分组,且在不增加参数

的情况下显著提高分割性能。ResNeSt模块由1个残差块和1个分离注意模块组成, 然而分离注意模块只利用全局平均池用于聚集空间信息, 而全局最大池能够收集不同对象特征的重要信息, 混合后可以将特征图全局最大限度地池化, 以推断更精细的通道注意。改进的ResNeSt主要目的是将一系列不同特征组的信息进行组合, 然后对这些组的特征映射重新校准。ResNeSt模块的详细结构如图2(a)所示, 输入 $X \in R^{H \times W \times C}$ 平均分成两个基组, 然后分别馈入两个具有相同结构的基数块。在每个基数块中, 基数组进一步均分并输入到两个并行分支。每

个分支由 1×1 和 3×3 卷积层、批量归一化(Batch Normalization, BN)和修正线性单元(ReLU)层组成, 输出大小为 $H \times W \times C/4$ 的特征图。

在每个基数块中应用分离注意模块, 以整合来自两个分支的特征图, 如图2(b)所示。首先通过元素求和将两个分支(表示为 U_1 和 U_2)的特征映射进行融合, 然后采用全局平均池化(gp)和全局最大池化(mp)生成通道统计信息 S , 再将两个全连接(Fully Connected, FC)层和1个softmax层应用于 S , 以获得 a_1 和 a_2 , 分别为 U_1 和 U_2 的通道注意权重。具体为




图1 MFU-Net总体架构

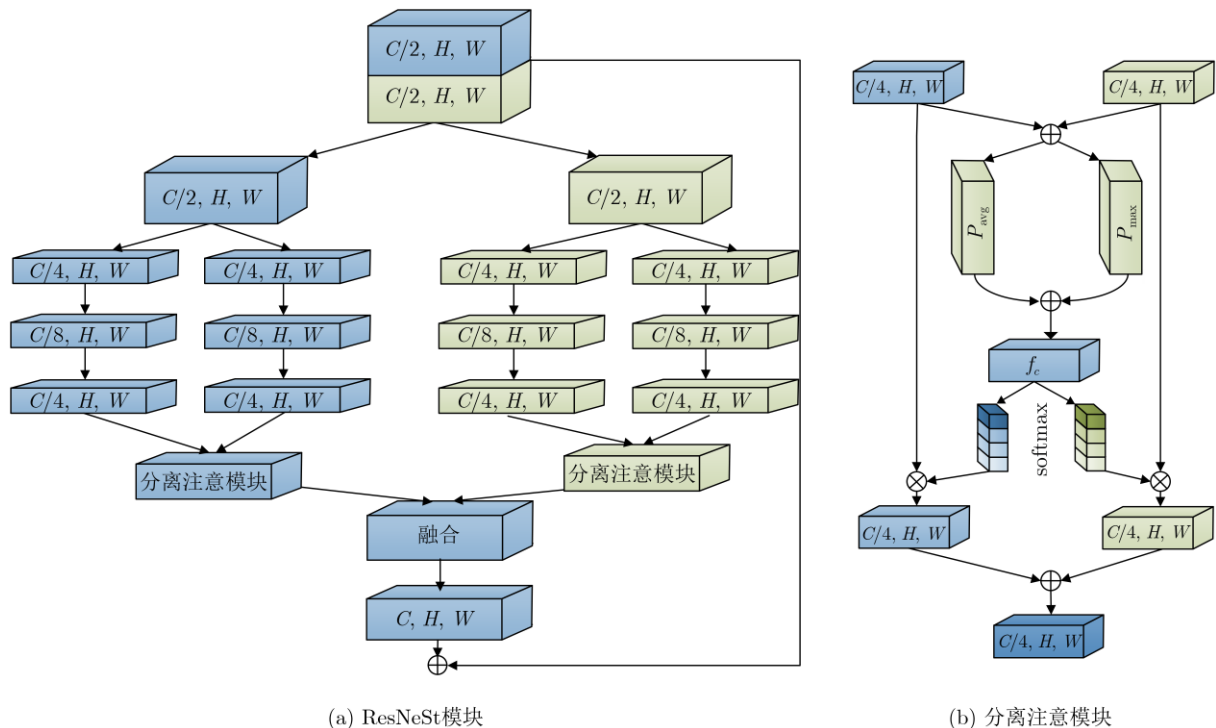


图2 改进的ResNeSt模块

$$s = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W [U_1(i, j) + U_2(i, j)] \quad (1)$$

$$a_i^k = \begin{cases} \frac{\exp(g_i(s^k))}{\sum_{j=1}^R \exp(g_j(s^k))}, & R > 1 \\ \frac{1}{1 + \exp(-g_i(s^k))}, & R = 1 \end{cases} \quad (2)$$

其中, k 表示分支数, 映射 g_i 表示通道拆分的权重。使用权重向量 \mathbf{a}_1 和 \mathbf{a}_2 , U_1 和 U_2 的加权结果以及基块 V 的输出为: $V_1 = \mathbf{a}_1 \times U_1$, $V_2 = \mathbf{a}_2 \times U_2$, $V = V_1 + V_2$ 。接下来, 两个基本块(表示为 V_1 和 V_2)的输出通过沿通道维度的串联和一个 1×1 卷积(表示为 $F_{1 \times 1}$)进行融合: $Z = F_{1 \times 1}(V_1, V_2)$ 。因此, 最终输出 Y 为: $Y = Z + T(X)$, 其中 T 表示特征恒等映射。

2.3 并行空间激活模块

在MFIU-Net中, 高分辨率特征图具有丰富的空间信息, 能精确定位血管的位置, 而低分辨率特征图具有深层次的语义信息, 有助于正确识别细小血管。为了更好地处理不同尺度的特征信息, 本文提出并行空间激活模块(Parallel Spatial Activation Module, PSAM), 减少下采样过程中语义信息的丢失。PSAM的结构如图3所示, 首先使用双线性插值将低分辨率获得的不同尺度特征映射上采样到原始图像大小。然后将相同大小的特征图传送到 1×1 卷积层中进行通道数的调整。再通过全局平均池化和最大池化, 将尺寸为 $48 \times 48 \times C$ 的注意力图重塑到 $1 \times 1 \times C$ 的特征图, 以聚合不同分辨率通道丰富的语义和空间信息, 使用元素求和合并每个特征图。再使用多层感知器和sigmoid函数确定通道




图3 并行空间激活模块

注意力图, 以获取每个通道的注意力权重系数 $\beta (\beta \in [0, 1])$, 从而得到通道加权后的注意力图。最后, 使用元素乘法将获得的相关权重系数分配到不同分辨率的通道, 以获得通道加权后的特征图。为了缓解梯度消失和梯度爆炸的问题, 添加跳跃连接。该模块计算过程为

$$y_{SA} = F \oplus F \times (\delta(P_a(F) \oplus P_m(F))) \quad (3)$$

其中, δ 表示sigmoid激活函数, p_a 和 p_m 分别表示全局平均池化和最大池化, F 表示不同通道的输入特征图, y_{SA} 表示最终的通道输出特征图。

2.4 多尺度密集特征金字塔模块

为了使网络捕获不同多尺度上下文血管特征信息。Wang等人^[16]提出密集网络(DenseNet)通过密集连接操作, 以加强特征之间的信息交互。Hu等人^[17]提出空洞空间卷积池化金字塔(Atrous Spatial Pyramid Pooling, ASPP)使用不同的扩张卷积, 以获取多尺度信息。本文结合并联、级联和扩张卷积的优点提出多尺度密集特征金字塔模块(Multiscale Dense Feature Pyramid module, MDFP), 其结构如图4所示。首先, 从前一个编码底层获得高分辨率特征图 $X_{in}^1 \in R^{H \times W \times C}$, 通过最大池化获得低分辨率特征图 $X_{in}^1 \in R^{H/2 \times W/2 \times C}$, 再对 X_{in}^1 进行密集扩张卷积操作, 得到 $X_{out}^1 \in R^{H \times W \times C}$ 。由于底层的输入血管图像的尺寸较小, 因此设计4个具有不同扩张率的扩张层, $r = [2, 3, 4, 5]$ 。每个扩张层由一个 1×1 卷积和 3×3 扩张卷积组成, 并在每个卷积运算之前进行BN和ReLU层操作, 为了减少模块的参数, 将每个扩张卷积的通道数设置为输入特征图通道数的 $1/4$, 每层的通道数输出为: $F + (d - 1) \times j$, 其中 F 为输入的通道数, d 为扩张层, j 为输入通道数的 $1/4$ 。同时将 X_{in}^2 进行密集扩张卷积操作, 并执行上采样操作以获得 $X_{out}^2 \in R^{H \times W \times C}$ 。最后连接 X_{out}^1 和 X_{out}^2 得到多尺度特征信息, 通过 1×1 卷积运算、BN, dropout操作得到包含多尺度特征信息的特征图 $X_{out} \in R^{H \times W \times C}$ 。




图4 多尺度密集特征金字塔模块

2.5 特征自适应模块

多分辨率融合输入利用PSAM注意机制提取丰富的全局语义和空间信息，所以不需要复杂的注意机制或多尺度卷积运算来捕获长期依赖性，例如Abraham等人^[18]和Zhang等人^[19]的注意门模块和多尺度跳跃连接模块。受文献[11]的启发，本文引用特征自适应模块(Feature Adaptive Module, FAM)融合粗、精网络之间的特征分布。为了恢复粗网络下采样阶段丢失的详细空间信息，采用卷积核大小为 3×3 和 1×1 的多层卷积减少粗、精网络之间的特征间隔，FAM的结构如图1所示。在融合中部署了3个功能FAM，分别对应着32, 64和128通道。在多分辨率融合输入的第1层，由于特征映射具有高分辨率的特征，使用FAM的6个基本块来匹配特征分布。对应的第2层和第3层，特征映射具有较低分辨率的特征，分别使用FAM4个和2个基本块来调整双边网络之间的特征。FAM是一个重量相对较轻、内存效率较高的模块，其参数数量相比AG模块和MSC模块较少。

3 实验数据与评价标准

3.1 实验数据集

本文采用眼底图像公共数据集DRIVE(Digital Retinal Images for Vessel Extraction)^[20], STARE (Structured Analysis of the Retinal)^[21]和CHASE_DB1(Child Heart and Health Study)^[22]进行测试。DRIVE数据集包含40张分辨率为565 pixel \times 584 pixel的彩色视网膜图像，训练集和测试集各包含20张视网膜图像。STARE数据集包含20张分辨率为700 pixel \times 605 pixel的彩色视网膜图像。由于STARE数据集未划分训练集和测试集，将该数据中前10张图像作为训练集，后10张图像作为测试集。CHASE_DB1数据集包含28张分辨率为999 \times 960 pixel的彩色视网膜图像，将前20张图像作为训练集，后8张图像作为测试集。本文将以上3个数据集第1位专家手动注释的图像作为本实验的参考标准。

3.2 数据预处理与补丁提取

由于眼底图像中，存在噪声、光照不均匀和硬性渗出物的现象，为了获得更好的血管分割结果，在数据增强之前对眼底图像进行预处理，如图5所示。首先将原始RGB眼底图像转化为血管与背景对比度较高的单通道灰色图像，然后使用对比度限制自适应直方图均衡化(Contrast Limited Adaptive Histogram Equalization, CLAHE)来改善灰度细节，最后使用局部自适应伽马(Gamma)矫正来抑制光照不均匀和伪影干扰。

3.3 评价指标

为了定量分析和评估所提的算法，采用4种在医学图像分割中广泛使用的评价指标：准确率(Acc)、灵敏度(Se)、特异性(Sp)和F1得分，具体计算为

$$Acc = \frac{TP + TN}{TP + TN + FP + FN} \quad (4)$$

$$Se = \frac{TP}{TP + FN} \quad (5)$$

$$Sp = \frac{TN}{TN + FP} \quad (6)$$

$$F1 = \frac{2TP}{2TP + FP + FN} \quad (7)$$

其中，TP, TN, FP和FN分别表示真阳性、真阴性、假阳性和假阴性；Acc表示所有像素的正确分类率；Se表示血管像素的正确分类率；Sp表示正确分类的非血管像素的比例；F1表示模型分割结果与金标准之间的相似程度。此外，本文还引入受试者工作特征曲线(Receive Operating Characteristic, ROC)下的面积(Area Under Curve, AUC)来评价模型的性能，其值越接近1，说明模型的总体性能越好。

4 实验结果与分析

4.1 实验环境及参数设置

本文算法实验使用的计算机配置为NVIDA




图5 各阶段预处理图像

GeForce RTX 3050Ti Laptop GPU, 运行内存 16 GB, 基于PyCharm的深度学习的框架, 运用python语言编程。在训练过程中, 使用初始学习率为 1×10^{-3} 的Adam算法作为优化方法。实验采用训练的批量batch_size为18, 迭代总数为50。此外, DropBlock中的block_size设置为 7×7 。

4.2 多重损失函数融合

由于血管与背景区域的像素比例较大, 边界附近的像素值通常非常相似, 使得模型容易误分类。为了平衡血管和背景区域之间的像素频率, 采用交叉熵损失函数作为双重损失函数的一个组成部分, 其定义为

$$L_1(p, y) = - \sum_{i \in \Omega} (y_i \ln p_i + (1 - y_i) \ln(1 - p_i)) \quad (8)$$

其中, Ω 表示像素的总数, y_i 和 p_i 分别表示像素 i 的真实标签和预测标签。

为了解决眼底图像中存在数据不平衡问题, 同时减少训练中过度拟合并获得快速收敛, 采用Dice loss损失函数作为双重损失函数的一个组成部分, 其定义为

$$L_2 = 1 - 2 \times \frac{\sum_{i=1}^K p_i g_i + \varepsilon}{\sum_{i=1}^K p_i^2 + \sum_{i=1}^K g_i^2} \quad (9)$$

其中, k 表示像素的总数; p_i 和 g_i 分别表示第 i 个像素的预测概率值和金标准真实值; ε 表示拉普拉斯平滑因子。

双重损失函数融合由交叉熵损失和Dice loss损失函数组成

$$L = \lambda_1 L_1 + \lambda_2 L_2 \quad (10)$$

在所提的MFIU-Net模型中, 根据表1可知, 当 λ_1 和 λ_2 为0.7和0.3时, 网络模型整体分割效果最佳。

4.3 可视化结果对比

为了证明MFIU-Net分割血管的优越性, 将其与最先进的算法以相同的实验条件和训练策略进行比较。图6为不同算法的血管分割结果图, 其中

1,2行为DRIVE数据集图像, 3,4行为STARE数据集图像, 5,6行为CHASE_DB1数据集图像。图6(a)为原始图像, 图6(b)为金标准图像, 图6(c)—图6(i)分别为U-Net^[23], U-Net++^[24], HRNet^[25], AttU-Net^[18], Ladder-Net^[26], BseResU-Net^[27]和本文算法结果图像。

由第1行的健康图像可知, 其他的模型对细小血管分割出现血管断裂、血管走势模糊的现象。本文算法对细小血管的分割稳健性较强, 且血管边界更加精确和清晰。第2行的病变图像可知, 其他的模型均出现细小血管分支中断及病理信息和噪声被误分割现象, 而本文算法的细小血管分支中断较少, 及较好地抑制病理信息和噪声的误分割。由第3行的健康图像可知, U-Net, HRNet和BseResU-Net无法提取轮廓和薄而细小的血管, 其他模型均出现主血管分割断裂现象。本文算法在主血管与薄而细小血管的分割上都比较健全, 对模糊边界的血管仍能获得更为清晰的分割结果。由第4行的病变图像可知, U-Net, U-Net++, HRNet和Ladder-Net分割结果图中均出现大量的噪声, 同时将病理信息作为血管分割, 造成较高的假阳性。本文算法和BseResU-Net较好地抑制伪影的干扰和病理信息误分割。由第5行的健康图像可知, 本文算法能较完整地分割主血管和细小血管, 使末端细小血管与主干血管平滑连接。其他模型均出现较多的细小血管末端缺少和视盘处主血管断裂的现象。由第6行的病变图像可知, 受图像伪影和病理区域的影响, U-Net, U-Net++, HRNet和AttU-Net均出血管交叉处断裂。本文算法的分割结果中虽出现了少量的误分割现象, 但其在主血管与细小血管的交叉处能清晰分割结果比其他算法更优。

基于上述分析, 本文算法在视网膜血管上能够更准确地区分血管与背景图, 同时可以更完整、准确提取血管的详细信息。此外, 本文算法在健康和病变图像的分割任务中都表现更好, 体现本文算法具有较强的鲁棒性。

为了更清楚地突出MFIU-Net的分割结果优于其他算法, 对不同算法血管分割结果进行详细对比,

表 1 对比实验结果

| λ_1 | λ_2 | Acc | Se | Sp | F1 | AUC |
|-------------|-------------|---------------|---------------|---------------|---------------|---------------|
| 0.3 | 0.7 | 0.9691 | 0.7982 | 0.9868 | 0.8249 | 0.9865 |
| 0.4 | 0.6 | 0.9689 | 0.8153 | 0.9836 | 0.8210 | 0.9850 |
| 0.5 | 0.5 | 0.9696 | 0.7866 | 0.9872 | 0.8194 | 0.9859 |
| 0.6 | 0.4 | 0.9688 | 0.8269 | 0.9825 | 0.8232 | 0.9860 |
| 0.7 | 0.3 | 0.9700 | 0.8273 | 0.9836 | 0.8279 | 0.9874 |

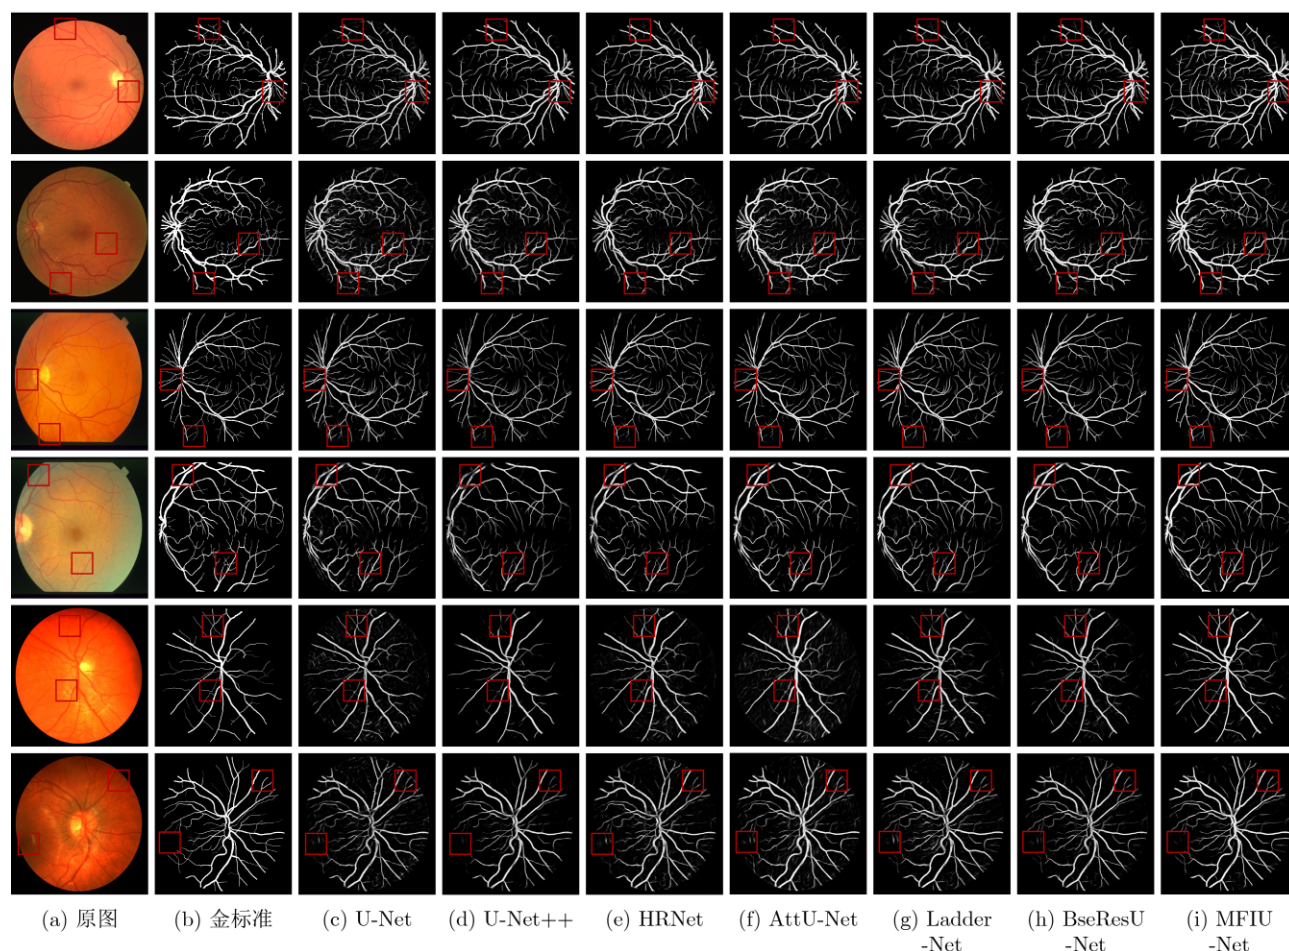


图6 不同算法视网膜血管分割结果

图6展示了MFIU-Net与其他6种算法在DRIVE, STARE和CHASE_DB1数据集上的局部分割图像。图7(a)和图7(b)分别为原始图像和局部区域,图7(c)—图7(j)分别为金标准、U-Net, U-Net++, HRNet, AttU-Net, Ladder-Net, BseResU-Net和MFIU-Net的局部区域分割结果。

由第1张血管局部区域分割结果图可知,其他6种模型在分割交叉血管时都出现了不同程度的断裂和分支末端缺失等现象,且对细小血管的识别较弱和纹理信息的丢失。相比之下,本文算法可以准确地检测上述血管,这主要归功于MDFP模块,该模块能有效提取多尺度特征,获得更多的血管细节信息;以及改进的ResNeSt模块,增强了对血管的分割能力有效突出细小血管信息;通过多分辨率融合输入结构对血管边界精确识别。对第2张局部分割结果分析可知,其他6种模型对主管管和交叉处的细小血管均出现了缺口或断裂等现象。本文算法分割出的血管比较平滑合理,且细小血管和交叉血管的详细信息保存完好,充分说明PSAM模块通过对不同分辨率的通道特征信息进行重新校准并融合,

提升了模型对细小血管分割的鲁棒性。通过第3张局部区域分割结果可知,本文算法分割的血管结构光滑、清晰、有更具体的边界及更少的噪声,说明FAM模块能有效抑制眼底图像中病理信息和伪影及噪声的干扰,而其他模型分割产生了带有假阳性预测的嘈杂结果。

实验结果表明,通过多分辨率融合输入结构、改进ResNeSt、PSAM模块、MDFP模块及引入FAM模块设计的MFIU-Net,可以分割血管的不同区域,获得比其他算法更好的分割结果。因此,该算法在复杂眼底血管结构分割中的优越性得到充分体现。

4.4 性能指标对比

为了定量分析实验结果,以评估本文算法,表2统计了不同算法在DRIVE, STARE和CHASE_DB1数据集上的性能指标。从表2可知,在DRIVE数据集中,本文提出的MFIU-Net大多数重要指标都优于其他算法,Se比BesResU-Net提升了3.94%,特别是Acc达到了最高为97.00%,同时F1和AUC分别为82.79%和98.74%,这证明了所提出的MFIU-Net优越性。在STARE数据集中,Acc和Se分别达




图 7 不同算法血管分割细节比较

表 2 不同算法的性能指标(%)

| 方法 | DRIVE | | | | | STARE | | | | | CHASE_DB1 | | | | |
|----------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|
| | Acc | Se | Sp | F1 | AUC | Acc | Se | Sp | F1 | AUC | Acc | Se | Sp | F1 | AUC |
| 文献[23] | 96.84 | 75.43 | 98.89 | 80.68 | 98.43 | 97.24 | 73.33 | 99.22 | 80.29 | 98.48 | 97.19 | 70.78 | 98.96 | 76.03 | 98.41 |
| 文献[24] | 96.95 | 79.00 | 98.68 | 81.96 | 98.65 | 97.35 | 76.80 | 99.06 | 81.63 | 98.65 | 97.21 | 72.74 | 98.86 | 76.67 | 98.46 |
| 文献[25] | 96.97 | 78.22 | 98.78 | 81.92 | 98.66 | 97.39 | 77.61 | 99.03 | 82.01 | 98.76 | 97.19 | 72.04 | 98.88 | 76.36 | 98.32 |
| 文献[18] | 96.85 | 78.15 | 98.65 | 81.30 | 98.37 | 97.25 | 77.18 | 98.91 | 81.12 | 98.53 | 97.08 | 78.00 | 98.36 | 77.11 | 98.10 |
| 文献[26] | 96.94 | 79.50 | 98.62 | 82.00 | 98.64 | 97.33 | 78.70 | 98.87 | 81.86 | 98.75 | 97.22 | 77.35 | 98.56 | 77.83 | 98.44 |
| 文献[27] | 96.95 | 81.59 | 98.43 | 82.41 | 98.69 | 97.34 | 78.92 | 98.87 | 81.98 | 98.79 | 97.23 | 81.16 | 98.30 | 78.64 | 98.62 |
| MFIU-Net | 97.00 | 82.73 | 98.36 | 82.79 | 98.74 | 97.47 | 82.86 | 98.68 | 83.37 | 98.90 | 97.48 | 83.24 | 98.43 | 80.57 | 98.93 |

到了97.47%和82.86%，优于其他先进算法。与传统的U-Net相比，本文Se从73.33%增加到82.86%，同时F1和AUC也分别从80.29%，98.48%增加到83.37%，98.90%，Sp略低于其他算法，这证明了所提的MFIU-Net有效性。在CHASE_DB1数据集中，与其他先进算法相比MFIU-Net除了Sp各项指标均达到了最高，在与BesResU-Net参数相当的情况下，Se提高了2.08%，Acc,F1和AUC分别提高了0.25%，1.93%和0.31%，这证明了所提的MFIU-Net高效性。

为了更直观体现MFIU-Net分割性能，图8表示不同算法在DRIVE,STARE和CHASE_DB1数据集上的ROC曲线走势，ROC曲线反映了假阳性(背景像素被误分割为血管像素)和真阳性(正确分割血管像素)之间的信息。由于图8可知，MFIU-Net的ROC曲线最接近左上角和最高的AUC值，充分说

明本文MFIU-Net比其他先进算法分类血管与非血管像素能力更强，更好地识别细小血管，有效地消除眼底图片中噪声的干扰。

以进一步分析不同算法分割单幅图像的性能，从图9(a)—图9(c)可以看出，MFIU-Net比其他先进算法的F1值均高，F1曲线波动较小、相对较平滑，充分说明了本文算法在不同的数据集均能够稳定地提取特征信息，并且在健康和病变的视网膜图像保持相对稳定的分割效果，模型的泛化性较强。

4.5 与其他先进算法比较

为了进一步说明本文算法在血管分割上的性能，将其与近年来在3个数据集上的先进算法进行比较，如表3、表4和表5所示，其中加粗值为该项最优值。本文算法在3个数据集上获得了最好的性能，其Acc都高于其他算法。由表3可知，文献[8]利用残差非局部注意提取多尺度特征，其Sp比本文算法

高0.16%，而本文算法Acc,Se,F1和AUC分别比其高1.19%，2.46%，0.73%和0.24%。此外，与相同文献[8]相比，本文算法在STARE1数据集上Acc, Se和AUC分别提高了0.12%，3.35%和0.34%。说明文献[8]致力于检测更多的血管，将背景中许多像素误分割为血管像素，而本文算法更准确地将血管与背景区分，并对不同的数据集具有更较强的泛化能力。由表4可知，本文算法表现出较好的性能，Acc和Se均高出其他算法许多。文献[10]AUC比本文算法高0.20%，但本文算法的Acc, Se和F1分别高出其

0.79%，2.84%和0.48。在CHASE_DB1数据集中，文献[10]F1比本文算法高2.36%，而本文算法的Acc和Se分别比其高0.81%和1.92%。由表5可知，文献[31]的Se和F1分别比本文算法高0.78%，但其Acc, Sp和AUC分别低于本文算法0.65%，0.42%和0.19%。综合3个数据集的性能指标，说明本文算法具有较好的泛化性能，也表现了其血管分割的优越性能。相对其他先进算法，本文算法能准确地区分血管与背景信息，精确提取血管特征信息，充分说明了本文算法的鲁棒性更强。




图 8 不同算法的ROC曲线




图 9 不同算法的F1性能曲线

表 3 DRIVE数据集对比结果

| 方法 | Acc | Se | Sp | F1 | AUC |
|----------|---------------|---------------|---------------|---------------|---------------|
| 文献[7] | 0.9568 | 0.8115 | 0.9780 | 0.8272 | 0.9810 |
| 文献[8] | 0.9692 | 0.8027 | 0.9852 | 0.8206 | 0.9850 |
| 文献[9] | 0.9581 | 0.7991 | 0.9813 | 0.8293 | 0.9823 |
| 文献[10] | 0.9565 | 0.7853 | 0.9818 | 0.8203 | 0.9834 |
| 文献[26] | 0.9561 | 0.7856 | 0.9810 | 0.8202 | 0.9793 |
| 文献[28] | 0.9566 | 0.7963 | 0.9800 | 0.8237 | 0.9802 |
| 文献[29] | 0.9573 | 0.7735 | 0.9838 | 0.8205 | 0.9816 |
| 文献[30] | 0.9858 | 0.7941 | 0.9798 | 0.8216 | 0.9847 |
| 文献[31] | 0.9581 | 0.8046 | 0.9805 | 0.8303 | 0.9827 |
| MFIU-Net | 0.9700 | 0.8273 | 0.9836 | 0.8279 | 0.9874 |

4.6 消融实验分析

为了更好地证明本文算法的有效性, 对其进行消融实验, 以比较不同模块的性能。本文将在原始U-Net结构上进行分步调整, 分别在DRIVE, STARE和CHASE_DB1数据集上进行实验, 表6表示不同模块的实验结果, 其中加粗项为该项指标的最优值。表中, M1表示U-Net基线; M2表示在U-Net中加入多分辨率融合输入结构; M3表示在M2中加入改进的ResNeSt; M4表示在M3中加入PSAM; M5表示在M4中加入MDFP; M6表示在M5中加入FAM, 即本文所提MFIU-Net。

在3个数据集中U-Net基线的Acc和Se较低, 说明该模型在正确提取血管的能力有一定的局限性,

主要原因是对局部和全局特征信息的提取能力较弱, 以及该模型易受对比度和噪声的干扰, 导致出现血管分割断裂和分割欠缺等现象。M2在U-Net基线上增加多分辨率融合输入结构, Acc和Se大幅度的上升, 说明多分辨率融合输入图像可以为网络提供更多的特征信息, 提高边界的精度, 提高细小血管分割的精度, 对提高分割精度具有积极意义。M3比较M2的Se分别提高了3.21%, 4.79%和4.50%, 说明改进的ResNeSt可以精确提取血管, 及传递更完整的血管表面特征, 缓解细小血管分割缺失问题。M4在Acc, Se, F1和AUC均有提升, 尤其是Se和F1分别提升了0.34%和0.05%, 2.98%和0.68%, 1.67%和1.07%, 说明PSAM通过多阶段的重复高分辨率与

表 4 STARE数据集对比结果

| 方法 | Acc | Se | Sp | F1 | AUC |
|----------|---------------|---------------|---------------|---------------|---------------|
| 文献[8] | 0.9735 | 0.7951 | 0.9883 | 0.8216 | 0.9856 |
| 文献[9] | 0.9673 | 0.8186 | 0.9844 | 0.8379 | 0.9881 |
| 文献[10] | 0.9668 | 0.8002 | 0.9864 | 0.8289 | 0.9900 |
| 文献[28] | 0.9641 | 0.7595 | 0.9878 | 0.8143 | 0.9832 |
| 文献[29] | 0.9701 | 0.7715 | 0.9886 | 0.8146 | 0.9881 |
| 文献[30] | 0.9640 | 0.7598 | 0.9878 | 0.8142 | 0.9824 |
| 文献[31] | 0.9665 | 0.7914 | 0.9870 | 0.8276 | 0.9864 |
| MFIU-Net | 0.9747 | 0.8286 | 0.9868 | 0.8337 | 0.9890 |

表 5 CHASE_DB1数据集对比结果

| 方法 | Acc | Se | Sp | F1 | AUC |
|--------|---------------|---------------|---------------|---------------|---------------|
| 文献[7] | 0.9664 | 0.8075 | 0.9841 | 0.8278 | 0.9872 |
| 文献[9] | 0.9670 | 0.8239 | 0.9813 | 0.8191 | 0.9871 |
| 文献[10] | 0.9667 | 0.8132 | 0.9840 | 0.8293 | 0.9893 |
| 文献[26] | 0.9656 | 0.7978 | 0.9818 | 0.8031 | 0.9839 |
| 文献[28] | 0.9610 | 0.8155 | 0.9752 | 0.7883 | 0.9804 |
| 文献[29] | 0.9655 | 0.7970 | 0.9823 | 0.8073 | 0.9851 |
| 文献[30] | 0.9608 | 0.8176 | 0.9704 | 0.7892 | 0.9865 |
| 文献[31] | 0.9673 | 0.8402 | 0.9801 | 0.8248 | 0.9874 |
| TP | 0.9748 | 0.8324 | 0.9843 | 0.8057 | 0.9893 |

表 6 消融实验分析(%)

| 方法 | DRIVE | | | | | STARE | | | | | CHASE_DB1 | | | | |
|----|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|
| | Acc | Se | Sp | F1 | AUC | Acc | Se | Sp | F1 | AUC | Acc | Se | Sp | F1 | AUC |
| M1 | 96.84 | 75.43 | 98.89 | 80.68 | 98.40 | 97.24 | 73.33 | 99.22 | 80.29 | 98.53 | 97.19 | 70.78 | 98.96 | 76.03 | 98.41 |
| M2 | 96.89 | 77.88 | 98.72 | 81.44 | 98.56 | 97.35 | 75.11 | 99.20 | 81.30 | 98.75 | 97.24 | 75.26 | 98.72 | 77.47 | 98.43 |
| M3 | 96.91 | 80.09 | 98.57 | 82.13 | 98.58 | 97.38 | 77.90 | 98.99 | 81.98 | 98.69 | 97.30 | 79.76 | 98.48 | 78.82 | 98.65 |
| M4 | 96.95 | 80.43 | 98.53 | 82.18 | 98.61 | 97.40 | 80.88 | 98.77 | 82.66 | 98.85 | 97.41 | 81.43 | 98.49 | 79.89 | 98.83 |
| M5 | 96.99 | 81.69 | 98.47 | 82.66 | 98.67 | 97.43 | 81.52 | 98.74 | 82.91 | 98.88 | 97.45 | 81.84 | 98.50 | 80.19 | 98.87 |
| M6 | 97.00 | 82.73 | 98.36 | 82.79 | 98.74 | 97.47 | 82.86 | 98.68 | 83.37 | 98.90 | 97.48 | 83.24 | 98.43 | 80.57 | 98.93 |

低分辨率信息交换和信息融合, 逐步更新现有分辨率特征图像, 生成高分辨率特征图像, 使空间预测血管信息更加准确。M5相对M4在各项指标上有进一步提升, 说明MDFP能获取不同大小的血管特征信息, 更好地学习血管周围的特征, 提高分割效果。M6在M5基础上增加FAM, 取得了最好的分割效果, 说明FAM使分割的主要目标集中在血管区域, 减少病理和噪声的干扰, 这表明其对最终血管分割结果的重要性。以上实验结果表明, 本文所提的MFIU-Net具有合理性和有效性。

5 结束语

本文提出一种多分辨率融合输入的U型视网膜血管分割双边模型, 以自动分割眼底图像中的血管。该模型的粗略分割网络以多分辨融合输入结构为主干, 获取丰富的语义信息, 生成高分辨率特征; 将设计的PSAM合并到优化的多分辨率主干中, 以产生丰富的语义和位置信息。另一精细分割网络, 利用U型结构弥补粗略分割网络的空间信息丢失。同时, 网络底层增加设计的MDFP增大感受野, 有效地提取图像的全局上下文特征信息。增加改进的ResNeSt代替传统卷积运算, 缓解分割结果边界模糊和细小血管不准确的问题。最后, 利用FAM对粗略和精细分割网络进行特征信息融合, 降低分割图像中的噪声。为网络设计注重细节的双重损失函数, 专注于细小血管部分多重优化学习过程。在DRIVE, STARE和CHASE_DB1数据集上与其他先进算法进行比较, 并对每个模块进行消融实验, 充分证明本文所提算法的优越性和有效性。在未来的工作中, 拟将提出更低复杂度和更具辨别力的模型, 可以明确地检测血管, 并进一步对其进行改进和优化。

参 考 文 献

- [1] 王娟, 赵建勇, 童龙. 老年2型糖尿病患者并发周围神经病变的影响因素分析[J]. 中国慢性病预防与控制, 2019, 27(1): 52-54. doi: 10.16386/j.cjpcd.issn.1004-6194.2019.01.014.
- [2] WANG Juan, ZHAO Jianyong, and TONG Long. Analysis of the influencing factors of peripheral neuropathy in elderly patients with type 2 diabetes[J]. *China Journal of Chronic Disease Prevention and Control*, 2019, 27(1): 52-54. doi: 10.16386/j.cjpcd.issn.1004-6194.2019.01.014.
- [3] YU Linfang, QIN Zhen, ZHUANG Tianming, *et al.* A framework for hierarchical division of retinal vascular networks[J]. *Neurocomputing*, 2020, 392: 221-232. doi: 10.1016/j.neucom.2018.11.113.
- [4] KHAWAJA A, KHAN T M, KHAN M A U, *et al.* A multi-scale directional line detector for retinal vessel segmentation[J]. *Sensors*, 2019, 19(22): 4949. doi: 10.3390/s19224949.
- [5] KHAWAJA A, KHAN T M, NAVEEDK, *et al.* An improved retinal vessel segmentation framework using frangi filter coupled with the probabilistic patch based denoiser[J]. *IEEE Access*, 2019, 7: 164344-164361. doi: 10.1109/access.2019.2953259.
- [6] 田丰, 李莹, 王静. 基于多尺度小波变换融合的视网膜血管分割[J]. 光学学报, 2021, 41(4): 0410001. doi: 10.3788/AOS202141.0410001.
- [7] TIAN Feng, LI Ying, and WANG Jing. Retinal blood vessel segmentation based on multi-scale wavelet transform fusion[J]. *Acta Optica Sinica*, 2021, 41(4): 0410001. doi: 10.3788/AOS202141.0410001.
- [8] 梁礼明, 盛校棋, 蓝智敏, 等. 基于多尺度滤波的视网膜血管分割算法[J]. 计算机应用与软件, 2019, 36(10): 190-196, 204. doi: 10.3969/j.issn.1000-386x.2019.10.033.
- [9] LIANG Liming, SHENG Xiaoqi, LAN Zhimin, *et al.* Retinal vessels segmentation algorithm based on multi-scale filtering[J]. *Computer Applications and Software*, 2019, 36(10): 190-196, 204. doi: 10.3969/j.issn.1000-386x.2019.10.033.
- [10] YANG Xin, LI Zhiqiang, GUO Yingqing, *et al.* DCU-Net: A deformable convolutional neural network based on cascade U-net for retinal vessel segmentation[J]. *Multimedia Tools and Applications*, 2022, 81(11): 15593-15607. doi: 10.1007/s11042-022-12418-w.
- [11] CHEN Yixuan, DONG Yuhan, ZHANG Yi, *et al.* RNA-Net: Residual nonlocal attention network for retinal vessel segmentation[C]. 2020 IEEE International Conference on Systems, Man, and Cybernetics (SMC), Toronto, Canada, 2020: 1560-1565. doi: 10.1109/smc42975.2020.9283248.
- [12] WANG Dongyi, HAYTHAM A, POTTENBURGH J, *et al.* Hard attention net for automatic retinal vessel segmentation[J]. *IEEE Journal of Biomedical and Health Informatics*, 2020, 24(12): 3384-3396. doi: 10.1109/jbhi.2020.3002985.
- [13] ZHANG Yuan, HE Miao, CHEN Zhineng, *et al.* Bridge-Net: Context-involved U-net with patch-based loss weight mapping for retinal blood vessel segmentation[J]. *Expert Systems with Applications*, 2022, 195: 116526. doi: 10.1016/j.eswa.2022.116526.
- [14] IBTEHAZ N and RAHMAN M S. MultiResUNet: Rethinking the U-Net architecture for multimodal biomedical image segmentation[J]. *Neural Networks*, 2020, 121: 74-87. doi: 10.1016/j.neunet.2019.08.025.
- [15] ZHANG Hang, WU Chongruo, ZHANG Zhongyue, *et al.* ResNeSt: Split-attention networks[EB/OL]. <https://arxiv.org/abs/2004.08955>, 2022.

- [13] LI Di, DHARMAWAN D A, NG B P, *et al.* Residual U-Net for retinal vessel segmentation[C]. 2019 IEEE International Conference on Image Processing (ICIP), Taipei, China, 2019: 1425–1429. doi: 10.1109/icip.2019.8803101.
- [14] ZHOU Tianyan, ZHAO Yong, and WU Jian. ResNeXt and Res2Net structures for speaker verification[C]. 2021 IEEE Spoken Language Technology Workshop (SLT), Shenzhen, China, 2021: 301–307. doi: 10.1109/slt48900.2021.9383531.
- [15] HU Jie, SHEN Li, and SUN Gang. Squeeze-and-excitation networks[C]. The 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Salt Lake City, USA, 2018: 7132–7141. doi: 10.1109/CVPR.2018.00745.
- [16] WANG Chang, ZHAO Zongya, REN Qiongqiong, *et al.* Dense U-net based on patch-based learning for retinal vessel segmentation[J]. *Entropy*, 2019, 21(2): 168. doi: 10.3390/e21020168.
- [17] HU Peijun, LI Xiang, TIAN Yu, *et al.* Automatic pancreas segmentation in CT images with distance-based saliency-aware DenseASPP network[J]. *IEEE Journal of Biomedical and Health Informatics*, 2021, 25(5): 1601–1611. doi: 10.1109/jbhi.2020.3023462.
- [18] ABRAHAM N and KHAN N M. A novel focal tversky loss function with improved attention U-Net for lesion segmentation[C]. 2019 IEEE 16th International Symposium on Biomedical Imaging (ISBI 2019), Venice, Italy, 2019: 683–687. doi: 10.1109/isbi.2019.8759329.
- [19] ZHANG Guokai, SHEN Xiaoang, CHEN Sirui, *et al.* DSM: A deep supervised multi-scale network learning for skin cancer segmentation[J]. *IEEE Access*, 2019, 7: 140936–140945. doi: 10.1109/access.2019.2943628.
- [20] STAAL J, ABRAMOFF M D, NIEMEIJER M, *et al.* Ridge-based vessel segmentation in color images of the retina[J]. *IEEE Transactions on Medical Imaging*, 2004, 23(4): 501–509. doi: 10.1109/tmi.2004.825627.
- [21] HOOVER A D, KOUZNETSOVA V, and GOLDBAUM M. Locating blood vessels in retinal images by piecewise threshold probing of a matched filter response[J]. *IEEE Transactions on Medical Imaging*, 2000, 19(3): 203–210. doi: 10.1109/42.845178.
- [22] OWEN C G, RUDNICKA A R, MULLEN R, *et al.* Measuring retinal vessel tortuosity in 10-year-old children: Validation of the computer-assisted image analysis of the retina (CAIAR) program[J]. *Investigative Ophthalmology & Visual Science*, 2009, 50(5): 2004–2010. doi: 10.1167/iovs.08-3018.
- [23] ALOM Z, HASAN M, YAKOPCIC C, *et al.* Recurrent residual convolutional neural network based on U-Net (R2u-Net) for medical image segmentation[EB/OL]. <https://arxiv.org/abs/1802.06955>, 2018.
- [24] ZHOU Zongwei, SIDDIQUEE M R, TAJBAKHS N, *et al.* UNet++: Redesigning skip connections to exploit multiscale features in image segmentation[J]. *IEEE Transactions on Medical Imaging*, 2020, 39(6): 1856–1867. doi: 10.1109/tmi.2019.2959609.
- [25] YU Changqian, XIAO Bin, GAO Changxin, *et al.* LiteHRNet: A lightweight high-resolution network[C]. The 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Nashville, USA, 2021: 10435–10445. doi: 10.1109/cvpr46437.2021.01030.
- [26] ZHUANG Juntang. LadderNet: Multi-path networks based on U-Net for medical image segmentation[EB/OL]. <https://arxiv.org/abs/1810.07810>, 2018.
- [27] LI Di and RAHARDJA S. BSEResU-Net: An attention-based before-activation residual U-Net for retinal vessel segmentation[J]. *Computer Methods and Programs in Biomedicine*, 2021, 205: 106070. doi: 10.1016/j.cmpb.2021.106070.
- [28] JIN Qiangguo, MENG Zhaopeng, PHAM T D, *et al.* DUNet: A deformable network for retinal vessel segmentation[J]. *Knowledge-Based Systems*, 2019, 178: 149–162. doi: 10.1016/j.knosys.2019.04.025.
- [29] LI Xiang, JIANG Yuchen, LI Minglei, *et al.* Lightweight attention convolutional neural network for retinal vessel image segmentation[J]. *IEEE Transactions on Industrial Informatics*, 2021, 17(3): 1958–1967. doi: 10.1109/tii.2020.2993842.
- [30] LV Yan, MA Hui, LI Jianian, *et al.* Attention guided U-Net with atrous convolution for accurate retinal vessels segmentation[J]. *IEEE Access*, 2020, 8: 32826–32839. doi: 10.1109/access.2020.2974027.
- [31] YUAN Yuchen, ZHANG Lei, WANG Lituan, *et al.* Multi-level attention network for retinal vessel segmentation[J]. *IEEE Journal of Biomedical and Health Informatics*, 2022, 26(1): 312–323. doi: 10.1109/jbhi.2021.3089201.
- 梁礼明: 男, 教授, 研究方向为机器学习、医学影像和系统建模等。
詹 涛: 男, 硕士生, 研究方向为医学图像分割。
雷 坤: 男, 硕士生, 研究方向为医学图像分割。
冯 骏: 男, 硕士生, 研究方向为医学图像分割。
谭卢敏: 女, 硕士, 讲师, 研究方向为医学影像。

责任编辑: 余 蓉