



激光杂志

*Laser Journal*

ISSN 0253-2743, CN 50-1085/TN

## 《激光杂志》网络首发论文

题目：基于局部特征增强的视网膜血管分割  
作者：王倩，辛月兰  
网络首发日期：2023-07-26  
引用格式：王倩，辛月兰. 基于局部特征增强的视网膜血管分割[J/OL]. 激光杂志.  
<https://kns.cnki.net/kcms2/detail/50.1085.TN.20230726.1134.012.html>



**网络首发：**在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

**出版确认：**纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

# 基于局部特征增强的视网膜血管分割

王倩<sup>1,2</sup>, 辛月兰<sup>1\*,2</sup>

1. 青海师范大学物理与电子信息工程学院, 西宁 810001
2. 省部共建藏语智能信息处理及应用国家重点实验室, 西宁 810001

**摘要:** 视网膜血管具有细小复杂的特点, 在对其进行分割时, 经常出现噪点、断裂和欠分割等问题。针对此现象, 提出一种基于局部特征增强的轻量化网络 LRU-Net, 以捕获更多细小血管特征。首先, 在通道注意力模块中加入特征提取模块, 对输入特征进行二次特征提取, 以得到更多的细节特征; 其次, 设计了一个特征融合模块, 在解码器中能更有效地融合高级和低级特性, 加强最终的特征表示; 最后, 设计了一个上下文聚合模块, 提取最深层特征不同分辨率的多尺度信息, 然后进行拼接, 使进入上采样的输入特征更加细化。在 FIVES 和 OCTA-500 数据集上的实验结果表明, 与基础网络 U-Net 相比, 本文所提方法在做到轻量化的同时, 视网膜血管分割的准确度也有了一定的提升, 在两个数据集上分别达到了 98.45%、97.05%。

**关键词:** 特征增强; 特征融合模块; 上下文聚合模块; 视网膜血管分割

**中图分类号:** TP391.4 **文献标志码:** A

## Retinal vascular segmentation based on local feature enhancement

WANG Qian<sup>1,2</sup>, XIN Yuelan<sup>1\*,2</sup>

1. School of Physics and Electronic Information Engineering, Qinghai Normal University, Xining 810001, China
2. The State Key Laboratory of Tibetan Intelligent Information Processing and Application, Xining 810001, China

**Abstract:** Retinal blood vessels are small and complex. When segmentation retinal blood vessels, noise, fracture and under segmentation often occur. To solve this problem, a lightweight network named LRU-Net based on local feature enhancement is proposed to capture more features of small blood vessels. Firstly, a feature extraction module is added to the channel attention module to extract secondary features from input features so as to obtain more detailed features. Secondly, a feature fusion module is designed, which can fuse the high and low features more effectively in the decoder, and strengthen the final feature representation. Finally, a context aggregation module is designed to extract multi-scale information with different resolutions of the deepest features, and then splicing it to make the input features into the upper sampling more detailed. Experimental results on FIVES and OCTA-500 data sets show that compared with U-Net, the proposed method not only achieves lightweight, but also improves the accuracy and Dice coefficient of retinal vessel segmentation to a certain extent.

**Key words:** Feature enhancement; Feature fusion module; Context aggregation module; Retinal vascular segmentation

**基金项目:** 国家自然科学基金项目 (No. 61662062), 青海省自然科学基金项目 (No. 2022-ZJ-929)

**作者简介:** 王倩 (1998-), 女, 硕士研究生, 主要研究方向: 图像处理与可视化。E-mail: 819065667@qq.com

**通讯作者:** 辛月兰 (1972-), 女, 博士, 教授, 主要研究生: 图像处理、模式识别与智能信息处理。E-mail: xinyue001112@163.com

# 1 引言

视网膜的形态结构能够反映出糖尿病视网膜病变、高血压和青光眼等疾病，在临床中对于医生的诊断具有重要意义，但眼底视网膜图像存在较多无关信息，给视网膜血管分割任务带来了挑战<sup>[1-4]</sup>。

近年来，深度学习的算法在图像分割领域得到了广泛的应用，2015 年，Long 等人<sup>[5]</sup>提出了全卷积神经网络，实现输入任意大小的图像。同年 Ronneberger 等人<sup>[6]</sup>提出了经典的 U-Net 网络，采用 U 型对称结构，加入跳跃连接实现特征重用，大大提高了分割精度。此后基于 U-Net 改进的网络层出不穷，2021 年，Sathananthavathi 等人<sup>[7]</sup>提出了基于 U-Net 的编码器增强架构，该网络增强了对特征的解码能力，但忽略了细小血管特征提取能力不足的问题。Cheng 等人<sup>[8]</sup>基于空间与通道注意力机制提出了自动化分割 U-Net，在跳跃连接前后加入注意力模块(efficient channel attention, ECA)<sup>[9]</sup>，优化了网络的输入与输出，但计算量大幅增加，是 U-Net 的 4.8 倍。Sun 等人<sup>[10]</sup>提出了 U 型自适应尺度网络，根据不同分辨率特征图中的肿块尺度自适应选择合适尺寸的卷积核进行运算，但该网络设计的模块对局部细小特征的捕捉并不到位，最终分割精度仅提升 0.60%。2022 年，Rahman 等人<sup>[11]</sup>利用分层视觉转换器的尺度特性设计了级联注意解码器，该模块通过抑制背景信息来增强远程和局部上下文，但对高级和低级特征直接拼接造成了特征融合不到位，出现分割结果不连续的情况。Guo 等人<sup>[12]</sup>提出了一个并行的非同构块，利用了卷积和自注意力的优势，然而自注意力机制会大幅增加网络的复杂度和计算量，且最终分割结果提升并不明显。上述改进网络在一定程度上提高了最终的分割精度，但计算量也随之大幅增加，因此本文致力于增强网络特征提取能力，

同时使网络更轻量化。

为了能提取到更多的局部细节特征，本文具体改进为：①改进了 ECA 模块，在该模块中添加一个 3×3 卷积，对输入特征进行二次特征提取，并将改进后的模块插入跳跃连接中；②在编码器部分插入设计的特征融合模块，该模块能够充分融合低级特征和编码器中的高级特征。③对深层特征不同分辨率的多尺度信息进行融合，使其在最后进入上采样的特征更加细化。

## 2 网络结构

### 2.1 整体架构

本文网络结构依旧使用 U-Net 的基本结构，分为编码器、解码器和跳跃连接三部分。其中编码器是的作用是提取图像的特征，U-Net 采用的是 3×3 卷积块，而本文考虑到网络的参数量及由于网络层数增加而引起的梯度消失、爆炸和网络退化的问题，编码器部分采用 ResNet 系列中的 ResNet34 来对图像进行特征提取，构成主干网络 ResU-Net，如图 1 中红框部分表示。

在 ResU-Net 的基础上，插入了本文所提的三个模块。首先，在跳跃连接部分，插入改进后的 ECA\_X 模块，对关键特征注意的同时对输入特征进行二次特征提取，并将注意后的特征与再次提取的特征相乘输出。其次，在解码器部分插入设计的轻量级特征融合模块(Lightweight feature fusion module, LFFM)，该模块对编码器输入的低级特征与解码器的高级特征进行有效融合。最后，在编码器最底层插入轻量级上下文聚合模块(Lightweight context aggregation module, LCAM)，该模块只针对最深层的高级语义特征进行不同分辨率的多尺度信息融合，使进入上采样的输入更加细化。整个改进后的网络命名为 LRU-Net，网络结构图如图 1 所示。

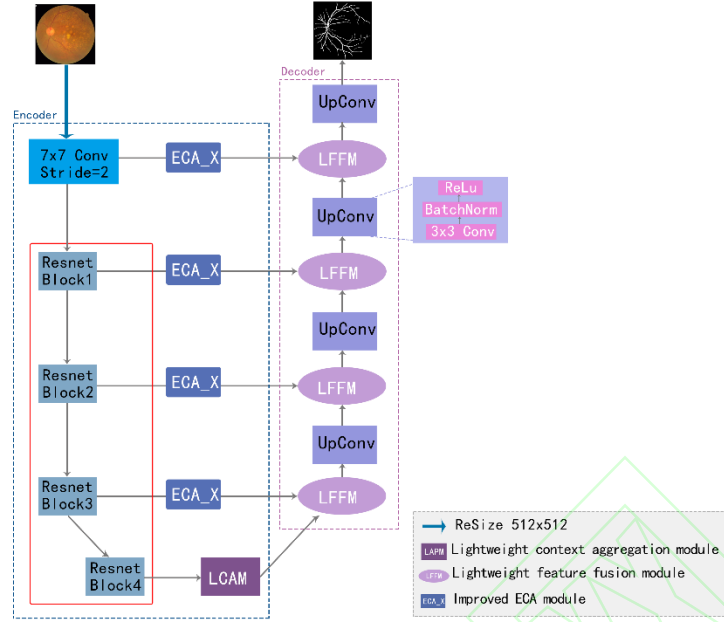


图 1 LRU-Net

## 2.2 ECA\_X 模块

通道注意力在改善深度卷积神经网络性能方面具有巨大潜力，但大多数注意力模块却是以复杂度和计算量为代价来实现更好的性能。通道注意力模块 ECA<sup>[9]</sup>的出现改变了这一现状，其使用一种无需降维的局部跨通道交互策略，自适应选择一维卷积的内核大小，确定局部跨通道交互的覆盖范围。该模块仅包含少量参数，同时带来显著的提升，故本文选取 ECA 模块在此基础上进行改进。

视网膜血管与其他医学病变影像图不同，

血管细而小且复杂交错，分割效果往往不尽人意。所以为了能正确地分割出每一条细小血管，需要将输入的视网膜图像的所有细节特征都尽可能地提取到。本文在 ECA 的内部增加了一个 3×3 的卷积，输入特征在通道上进行交互的同时对输入特征进行二次特征提取，以得到更多的特征信息，最后将其与经跨通道交互后的特征相乘输出，以此达到提高特征表示能力的目的。改进后的 ECA 模块图 2 所示，红框中为改进部分。




图 2 ECA\_X 模块

输入特征先进行全局池化，然后通过一个部分连接层  $FC[k]$ ，最后经过一层 Sigmoid 函数激活，其中  $k$  为卷积核大小，可自适应计算得出：

$$k = \left\lceil \frac{\log_2 C + b}{\gamma} \right\rceil_{add}, \quad \gamma = 2, \quad b = 1 \quad (1)$$

上式中  $C$  是通道数， $\gamma$ ， $b$  是超参数， $\lceil \cdot \rceil$  表示取最邻近的奇数。ECA\_X 运算表示为：  
 $ECA\_X(x) = \sigma(Con v_{1d}^{1 \times 1}(GAP(x))) \times Con v_{2d}^{3 \times 3}(x)$  (2)  
 其中， $\sigma$  是 Sigmoid 激活函数，GAP 是全局平均池化。

### 2.3 LFFM 特征融合模块

U-Net 编码器部分通过上采样方式逐步将包含复杂语义信息的特征图恢复到原始分辨率，同时在编码器中直接融合低级和高级特征，以实现特征重用。然而这种通过跨层方式将浅层的低级特征与编码器中的高级特征直接连接，不足以充分融合两类特征，且两

者特征相差巨大，融合效果不好。本文在 UAFM<sup>[13]</sup>模块的启发下，提出了 LFFM 模块。先对低级特征进行一次  $1 \times 1$  的卷积运算，缩小浅层低级特征与编码器高级特征的信息差，再将两者融合。然后通过通道注意力抑制无用信息通道，增强有用信息通道，来加强特征表示。LFFM 的结构如图 3 所示。




图 3 LFFM 模块

第一步，将低级语义信息输入  $1 \times 1$  卷积中，整合多个通道的信息，使网络提取的特征更加丰富。生成低级特征图  $X' \in R^{C \times 1 \times 1}$ 。

第二步，连接两类特征，生成通道数为  $2C$  的特征图  $M \in R^{2C \times H \times W}$ 。然后利用 ReLU 函数对特征进行重新加权，重新加权后的特征图通过一个全连接层，对特征进行精炼，最后利用 Sigmoid 函数对特征的通道进行重新加权，获得通道注意特征向量  $S \in R^{2C \times 1 \times 1}$ 。

第三步，将通道注意特征向量与特征图进行加权，生成特征  $Z \in R^{2C \times H \times W}$ 。

此过程对应的公式如下：

$$X' = \delta(BN(Conv_{1d}^{1 \times 1}(x))) \quad (3)$$

$$M = Concat(X', Y) \quad (4)$$

$$S = \delta(W(\gamma(M))) \quad (5)$$

$$Z = \delta(M, S) \quad (6)$$

其中， $\delta$  代表 Sigmoid 函数，BN 代表批归一化层， $\gamma$  代表 ReLU 函数，W 代表全连接层。

### 2.4 LCAM 模块

为了提高视网膜血管的分割精度，本文受 Peng 等人<sup>[13]</sup>提出的简单的金字塔池模块 SPPM 和 Sun 等人<sup>[10]</sup>提出的自适应尺度模块 ARM 启发下，设计了一个轻量级的上下文聚合模块 LCAM。该模块结合了 ARM 捕获不同尺度的特征信息的方法和 SPPM 简洁、轻量化的架构，能够保证在不增加过多参数量的同时，能有效聚合编码器输出的最深层特征，其结构图如图 4 所示：




图 4 LCAM 模块



第一步，根据输入  $X$  的分辨率，在三个分支中自适应地选择包含合适尺度卷积核的分支对输入  $X$  进行特征提取。三个分支具有三个不同空洞率的  $3 \times 3$  卷积核，本文设置的三个空洞率分别为 6, 12, 18。通过这三种不同的卷积运算，生成特征图  $\{X1, X2, X3\}$ ，然后将  $\{X1, X2, X3\}$  通过逐像素求和的方式进行融合，得到特征图  $M$ 。

第二步，为了弥补输出特征缺少全局上下文信息的缺点，在 PSPNet<sup>[14]</sup> 的启发下，添加一个全局特征提取分支，将输出  $X$  先用全局平均池化捕获特征的全局上下文语义信息，再使用  $1 \times 1$  卷积细化全局特征信息，得到特征图  $N$ 。

第三步，将前面两步所得到的特征图  $M$  与  $N$  进行合并，将合并后的特征再经过一个  $1 \times 1$  卷积层，使特征恢复到原始分辨率。三个步骤的公式分别如下：

$$X1: X \rightarrow A \in R^{C \times H \times W} \quad (7)$$

$$X2: X \rightarrow B \in R^{C \times H \times W} \quad (8)$$

$$X3: X \rightarrow C \in R^{C \times H \times W} \quad (9)$$

$$M = X1 + X2 + X3 \quad (10)$$

$$N = \eta(W(F_{GAP}(X))) \quad (11)$$

$$Z = W(Concat(M, N)) \quad (12)$$

其中， $F_{GAP}$  代表全局平均池化层， $W$  代表  $1 \times 1$  卷积层， $\eta$  代表双线性插值方法。

## 3 实验

### 3.1 数据集与预处理

本文所有实验均在 FIVES<sup>[15]</sup> 和 OCTA-500<sup>[16]</sup> 两个数据集上进行。其中 FIVES 数据集于 2022 年在 Nature 上发布，共有 800 张高分辨率多疾彩色眼底照片，是目前公开最大的眼底视网膜数据集。本文将前 600 张作为训练集，后 200 张作为测试集。OCTA-500 数据集包含 500 张眼球图像，本文将其中前 400 张作为训练集，后 100 张作为测试集。

为了使分割结果更好，本文对 FIVES 数据集进行了两次预处理。首先，提取了绿色通道上的图像，因为在三个通道上的图像，绿色通道上的图像对比度最强。其次，对提取后的图像进行限制对比度自适应直方图均衡化，对图像每个子块的直方图进行对比度限制。两次预处理后的图像如图所示：




图 5 预处理后的图像

### 3.2 实验环境与参数

本实验使用的算力系统为 RTX 3090，显存大小为 24GB，深度学习框架为 PyTorch 1.11.0，编程语言为 Python3.8。实验过程中设置的初始学习率为 0.05，最大迭代次数为 30，batchsize 为 6。

### 3.3 评价指标

本文选取了医学图像分割领域常用的五个评价指标对实验结果进行评估与分析，分别为 Dice 系数、灵敏度 (Sen)、特异性 (Spe)、交并比系数 (MIou) 以及准确度 (ACC)，其公式如下：

$$ACC = \frac{T_P + T_N}{T_P + F_P + T_N + F_N} \quad (13)$$

$$Sen = \frac{T_P}{T_P + F_N} \quad (14)$$

$$Spe = \frac{T_N}{T_P + F_P} \quad (15)$$

$$Dice = \frac{2 \times T_P}{2 \times T_P + F_P + F_N} \quad (16)$$

$$MIou = \frac{1}{K+1} \sum_{i=0}^K \frac{T_P}{T_P + F_P + F_N} \quad (17)$$

其中  $T_P$  表示正确分割血管的像素点个数， $T_N$  表示正确分割背景的像素点个数， $F_P$  表示将背景错误分割成血管的像素点个数， $F_N$  表示将血管错误分割成背景的像素点个数。上述五个评价指标的数值越大，表示分割效果越好。本文以 Dice 系数为主要评价指标，Dice 系数的值越大说明分割结果越接近金标准，与金标准的相似性越高。

### 3.4 模型有效性分析

#### 3.4.1 ECA\_X 模块

为了验证 ECA\_X 模块的有效性，现将 UNet 网络、主干网络 ResU-Net、在跳跃连接中添加 ECA 模块的网络与在跳跃连接中添加 ECA\_X 模块的网络以 Dice 系数为标准进行对比。

从表 1 可以看到在添加了 ECA 模块后在两个数据集上 Dice 系数分别上涨了 0.21%、0.64%。而替换成 ECA\_X 模块之后, Dice 系

数上涨了 0.88%和 0.72%, 比 ECA 模块上涨的点数还要高, 这说明 ECA\_X 模块比 ECA 模块的提升效果更好。

表 1 ResU-Net+ECA 与 ResU-Net+ECA\_X 的 Dice 系数对比结果

网络模型	U-Net	ResU-Net	ResU-Net+ECA	ResU-Net+ECA_X
FIVES 数据集	0.8854	0.8820	0.8841	0.8908
OCAT-500 数据集	0.8176	0.8145	0.8209	0.8217

本文同时还将三个网络的参数量和计算复杂度进行了对比, 如表 2 所示。在 ResU-Net 的基础上添加 ECA 模块后, 参数量和计算复杂度并没有显著增加, 仅增加的参数量几乎可以忽略不记, 但换成 ECA\_X 模块后, 参数量上涨了 0.77M, 而计算量上涨了 3.64G,

计算量上有了明显的增幅, 这是由于添加了 3×3 卷积后, 对输入特征进行了二次特征提取, 卷积运算量增加了, 但同时效果也是明显的, 在主干网络基础上 Dice 系数有了较好的提升。

表 2 ResU-Net+ECA 与 ResU-Net+ECA\_X 的参数对比结果

网络模型	U-Net	ResU-Net	ResU-Net+ECA	ResU-Net+ECA_X
参数量(M)	31.04	24.01	24.01	24.78
FLOPs(G)	54.69	37.68	37.68	41.32

### 3.4.2 LFFM 模块

在添加了 ECA\_X 模块的基础上, 继续添加本文设计的 LFFM 模块, 该模块能有效融合低级和高级语义信息, Dice 系数对比结果与参数量对比结果如表 3、4 所示。其中 LRU-Net\*表示在添加了 ECA\_X 的基础上又在编码器部分添加了 LFFM 模块后网络。

在继续添加了 LFFM 模块后, 网络的 Dice 系数在只添加 ECA\_X 模块的基础上又上涨了 0.22%, 0.19%, 而网络的参数量上涨

了 0.87M, 计算量上涨了 4.08G。如表 3、4 可以看出, LRU-Net 的参数量和计算量一直是小幅上涨, 而 Dice 系数也不断在上涨, 比主干网络 Res-Unet 高出 1.10%和 0.91%。此外, LRU-Net 的参数量是一直低于 U-Net 的, 但 Dice 系数却比 U-Net 高出 0.76%和 0.60%。可见本文设计的 LFFM 模块是轻量化的, 在没有增加过多参数和计算量的同时提高了网络的 Dice 系数。

表 3 ResU-Net+ECA\_X 与 LRU-Net\*的 Dice 系数对比

网络模型	U-Net	ResU-Net	ResU-Net+ECA_X	LRU-Net*
FIVES 数据集	0.8854	0.8820	0.8908	0.8930
OCAT-500 数据集	0.8176	0.8145	0.8217	0.8236

表 4 ResU-Net+ECA\_X 与 LRU-Net\*参数量对比

网络模型	U-Net	ResU-Net	ResU-Net+ECA_X	LRU-Net*
参数量(M)	31.04	24.01	24.78	25.65
FLOPs(G)	54.69	37.68	41.32	45.40

### 3.4.3 LCAM 模块

在 LRU-Net\*的基础上, 继续在网络底层添加最后一个模块 LCAM, 该模块只针对编码器输出的最深层特征进行上下文融合操作。实验对比结果和网络参数量比较如表 5、6 所示。其中 LRU-Net 表示在 LRU-Net\*基础上添加了 LCAM 模块后的网络。

从表 5、6 可以看到, 在添加了 LCAM 模块之后网络的参数量和计算量小幅增加, 但 Dice 系数却在之前的 LFFM 和 ECA\_X 模

块基础上又提升了 0.26%, 0.48%, 且整个改进后的 LRU-Net 网络在计算量低于 U-Net 的基础上, Dice 系数却比 U-Net 高出 1.02%和 1.08%。并且添加三个模块后的 LRU-Net 比主干网络 ResU-Net 的 Dice 系数高出 1.36%和 1.39%, 说明本文添加的三个模块能有效提高网络的性能。综上可以说明, 本文所提网络均是轻量级的, 在控制参数量和计算量的同时很好的提升了网络的 Dice 系数。

表 5 LRU-Net\*与 LRU-Net 的 Dice 系数对比

网络模型	U-Net	ResU-Net	LRU-Net*	LRU-Net
FIVES 数据集	0.8854	0.8820	0.8930	0.8956
OCA-500 数据集	0.8176	0.8145	0.8236	0.8284

表 6 LRU-Net\*与 LRU-Net 参数量对比

网络模型	U-Net	ResU-Net	LRU-Net*	LRU-Net
参数量(M)	31.04	24.01	25.65	33.52
FLOPs(G)	54.69	37.68	45.40	47.41

### 3.5 与先进方法定量对比

为了进一步证明本文网络的有效性, 将本文所提网络 LRU-Net 与现有网络进行对比。分别是 2021 年的 EEA Unet<sup>[7]</sup>、LFSCA-U-Net<sup>[8]</sup>、ASU-Net<sup>[10]</sup>网络和 2022 年的 PVT-CASCADE<sup>[11]</sup>、UNet-2022<sup>[12]</sup>网络, 对比的结果如表 7, 8 所示。

在 FIVES 数据集上, 五项评价指标皆是本文所提网络 LRU-Net 的数值最高, Dice 系数达到了 89.56%, ACC 达到了 98.45%, 灵敏度 Sen 达到了 89.92%, 特异性 Spe 达到了 99.13%, MIou 系数达到了

89.71%, 均高于表中其他五个网络的数值, 说明相比于其他五个网络 LRU-Net 的分割结果更接近金标准, 分割精确度更高, 效果更好。

在 OCTA-500 数据集上, 本文所提的 LRU-Net 的灵敏度 Sen 达到了 82.44%, 仅比最好的 LFSCA-U-Net 低 0.32%, 而除了灵敏度外, LRU-Net 的其他四个指标皆为最好, 均高于表 8 中其他网络。

综上所述, 本文所提 LRU-Net 优于其他五个网络, 在精度和其他数值上有较大的提升。

表 7 FIVES 数据集对比结果

Method	Dice	MIou	ACC	Sen	Spe
EEA Unet <sup>[7]</sup>	0.8537	0.8607	0.9782	0.8498	0.9886
ASU-Net <sup>[10]</sup>	0.8766	0.8803	0.9815	0.8718	0.9904
PVT-CASCADE <sup>[11]</sup>	0.8619	0.8676	0.9794	0.8583	0.9892
UNet-2022 <sup>[12]</sup>	0.8382	0.8480	0.9762	0.8472	0.9863
LFSCA-U-Net <sup>[8]</sup>	0.8904	0.8924	0.9837	0.8886	0.9913
Ours	0.8956	0.8971	0.9845	0.8992	0.9913



表 8 OCAT-500 数据集对比结果

Method	Dice	MIoU	ACC	Sen	Spe
EEA Unet <sup>[7]</sup>	0.8090	0.8222	0.9675	0.8137	0.9817
ASU-Net <sup>[10]</sup>	0.8124	0.8249	0.9682	0.8198	0.9818
PVT-CASCADE <sup>[11]</sup>	0.8130	0.8252	0.9679	0.8111	0.9826
UNet-2022 <sup>[12]</sup>	0.7927	0.8032	0.9609	0.8114	0.9809
LFSCA-U-Net <sup>[8]</sup>	0.8260	0.8358	0.9703	0.8276	0.9836
Ours	0.8284	0.8376	0.9705	0.8244	0.9843

为了能更加直观的对比 LRU-Net 与其他五个网络的结果，现将网络的分割结果图进行对比，如图 6，7 所示。从图 6 可以看到，在红框部分其他五个网络在分割血管末端时出现了不同程度的断裂和噪点，而 LRU-Net 不仅完整地分割到了末端血管且并未出现噪点，分割结果干净完整。从图 7 来看，红框部分其他五个网络对末端细血管的特征提取并不到位，出现了不

同程度的欠分割和不连续的情况，而 LRU-Net 对于末端血管的分割更接近金标准且出现断裂和分割不到位的情况更少。此外，其他五个网络还出现了误分割现象，将背景误识别成了血管，整个分割结果断断续续且不完整。而 LRU-Net 的分割结果连续，出现断裂的情况较少，整个分割结果更接近金标准，说明本文的分割结果是优于其他五个网络的。

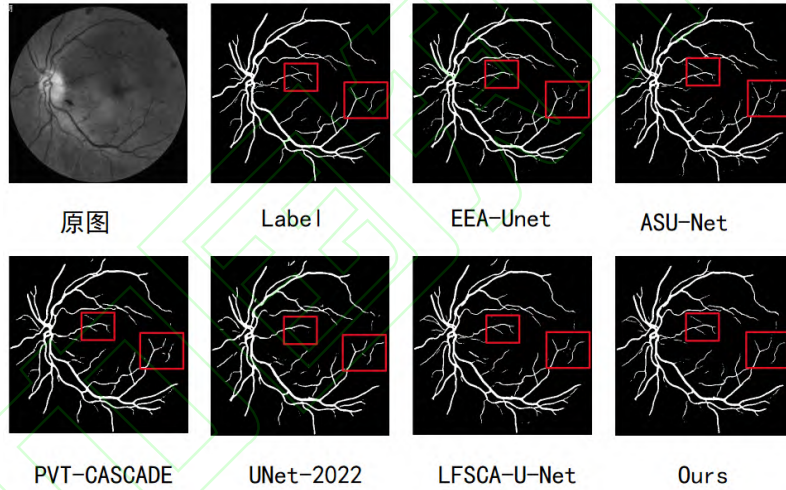


图 6 FIVES 数据集实验结果




图 7 OCTA-500 数据集实验结果

## 4 总结

本文针对视网膜血管分割精度不高,经常出现分割断裂或者分割不到末端细小血管的问题,提出了增强特征提取、特征融合以获得更多细小特征的方法。本文在 ECA 模块中加入  $3 \times 3$  卷积,增强对细节特征的提取。同时提出了 LFFM 模块,能有效融合浅层的低级特征和编码器中的高级特征,使得在上采样过程中能捕获更多的有用的特征信息。最后,针对编码器输出的最深层特征设计了 LCAM 模块,该模块对高级语义特征能进行多尺度特征聚合,使得进入上采样的特征更加丰富,提高了特征表达能力。实验结果表明,本文所提的 LRU-Net 网络具有更好的分割能力,分割出来的血管更加完整连续。但本文在很多地方依旧有提升的空间,后续工作将聚焦于如何利用现有技术能快速且正确地分割血管,无限接近专家标注结果,并且能够投入到实际生活当中,辅助医生诊断治疗。

## 5 参考文献

- [1] TING D S W, WONG T Y. Eyeing cardiovascular risk factors[J]. Nature Biomedical Engineer, 2018, 2(3): 140-141.
- [2] SRINIDHI C, APARNA P, RAJAN J. Recent advancements in retinal vessel segmentation[J]. Journal of Medical Systems, 2017, 41(4): 1-22.
- [3] 金鹭, 张寿明. 基于 U-Net 网络改进算法的视网膜血管分割研究[J]. 光电子激光, 2022, 33(8): 887-896.
- [4] Fraz M M, Remagnino P, Hoppe A, et al. Blood vessel segmentation methodologies in retinal images-a survey[J]. Computer Methods and Programs in Biomedicine, 2012, 108(1): 407-433.
- [5] LONG J, SHELHAMER E, DARRELL T. Fully convolutional networks for semantic segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 39(4): 640-651.
- [6] RONNEBERGER O, FISCHER P, BROX T. U-net: Convolutional networks for biomedical image segmentation[C]//18th International Conference on Medical Image Computing and Computer-Assisted Intervention, October 5-9, 2015, Munich, Germany. Berlin: Springer, 2015: 234-241.
- [7] Sathananthavathi V, Indumathi G. Encoder Enhanced Atrous (EEA) U-Net architecture for Retinal Blood vessel segmentation[J]. Cognitive Systems Research. 2021, 67: 84-95.
- [8] 陈弘扬, 高敬阳, 赵地, 等. LFSCA-U-Net: 基于空间与通道注意力机制的肝纤维化区域分割网络[J]. 中国图象图形学报, 2021, 26(9): 14.
- [9] Wang Q, Wu B, Zhu P, et al. ECA-Net: Efficient Channel Attention for Deep Convolutional Neural Networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2020: 11531-11539.
- [10] Sun K X, Xin Y L, Ma Y D, et al. ASU-Net: U-shape Adaptive Scale Network for Mass Segmentation in Mammograms[J]. Journal of Intelligent and Fuzzy Systems, 2021(6): 1-16.
- [11] Rahman M M, Marculescu R. Medical Image Segmentation via Cascaded Attention Decoding[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2023: 6222-6231.
- [12] Guo J, Zhou H Y, Wang L, et al. UNet-2022: Exploring Dynamics in Non-isomorphic Architecture[J]. arXiv preprint arXiv:2210.15566, 2022.
- [13] Peng J, Liu Y, Tang S, et al. Pp-liteseg: A superior real-time semantic segmentation model [J]. arXiv preprint arXiv:2204.02681, 2022.
- [14] Xu L, Choy C, Li Y W. Deep sparse rectifier neural networks for speech denoising [C]. IEEE International Workshop on Acoustic Signal Enhancement. 2016: 1-5.

- [15] Jin K, Huang X, Zhou J, et al. FIVES: A Fundus Image Dataset for Artificial Intelligence based Vessel Segmentation[J]. Scientific Data, 2022, 9(1): 475.
- [16] Mingchao Li et al. Image Projection Network: 3D to 2D Image Segmentation in OCTA Images[J] IEEE Transactions on Medical Imaging, 2020: 39(11): 3343-3354.

