

# 基于残差挤压激励与密集空洞卷积的视网膜血管分割

徐 艳<sup>1,2</sup>, 张 乾<sup>1,3\*</sup>, 吕义付<sup>1,2</sup>

(1. 贵州民族大学 数据科学与信息工程学院, 贵阳 550025;

2. 贵州省模式识别与智能系统重点实验室, 贵阳 550025;

3. 贵州民族大学教务处, 贵阳 550025)

**摘要:**针对现有视网膜血管分割技术存在视网膜血管分割精度不高和病灶区域误分割的问题,提出对 U 型网络改进,结合密集空洞卷积(dense atrous convolution, DAC)模块与残差挤压激励(residual squeeze and excitation, RSE)模块的视网膜血管分割模型(DACRSE-Unet)。该模型采用改进集成随机失活块(DropBlock)的残差结构,不仅可以构建深层网络来提取更复杂的血管特征,还可以有效缓解过拟合;此外,为了进一步提高网络的表达能力,在改进残差块的基础上引入挤压激励模块(squeeze and excitation, SE);同时,为获取血管更多的上下文信息,在模型中引入 DAC 模块来实现对视网膜血管的精准分割;最后,在不同数据集上进行验证。结果表明, DACRSE-Unet 模型的接受者操作特性曲线下面积分别为 0.986 9 和 0.996 4, 灵敏度分别为 0.822 6 和 0.877 9, 准确率分别为 0.969 2 和 0.983 0, 整体分割效果比其他模型更好。

**关键词:**U 型网络;视网膜血管;图像分割;残差挤压激励模块;注意力机制;密集空洞卷积模块

中图分类号:TP391

文献标志码:A

## Retinal Vascular Segmentation Based on Residual Squeeze and Excitation and Dense Atrous Convolution

XU Yan<sup>1,2</sup>, ZHANG Qian<sup>1,3\*</sup>, LYU Yifu<sup>1,2</sup>

(1. School of Data Science and Information Engineering, Guizhou Minzu University, Guiyang 550025, China;

2. Guizhou Key Laboratory of Pattern Recognition and Intelligent System, Guiyang 550025, China;

3. Office of Academic Affairs, Guizhou Minzu University, Guiyang 550025, China)

**Abstract:** As existing retinal vascular segmentation technologies have such problems as low accuracy of retinal vascular segmentation and mis-segmentation of lesion areas, a modified retinal vessel segmentation algorithm for U-Net was proposed, and a DACRSE-Unet was designed that combines dense atrous convolution (DAC) module and residual squeeze and excitation (RSE) module. The network adopts the residual structure of improved integrated DropBlock, which can not only build a deep network to extract more complex vascular features, but also effectively alleviate overfitting. In addition, in order to further improve the expression ability of the network, a squeeze and excitation (SE) module is introduced on the basis of improving the residual block. At the same time, in order to obtain more contextual information about blood vessels, a DAC module is introduced in the middle of the network to achieve precise segmentation of retinal blood vessels. The proposed algorithm was validated on different datasets, with area under receiver operating characteristic curve of 0.986 9 and 0.996 4, sensitivity of 0.822 6 and 0.877 9, accuracy of 0.969 2 and 0.983 0, respectively. The overall segmentation effect is better than other algorithms.

**Keywords:** U-Net; retinal blood vessels; image segmentation; residual squeeze and excitation module; attention mechanism; dense atrous convolution module

随着时代的发展,在医学图像分割领域关于眼底视网膜血管图像分割技术的关注日益增加,这是因为视网膜血管图像包含丰富的背景结构信息,可为糖尿病和高血压等疾病提供重要的临床信息,视网膜血管分割

收稿日期:2023-05-05

基金项目:贵州民族大学校级科研项目(GZMUZK[2021]YB23)。

第一作者简介:徐艳(1997-),女,硕士研究生,主要从事图像处理、机器学习与模式识别的研究; \* 通信作者:张乾(1984-),男,博士,教授,主要从事图像处理、机器学习与模式识别的研究。

准确与否可极大影响相关疾病的诊断。视网膜血管图像的正确分割不仅可用于评估和监测各种眼科疾病,还能反映糖尿病和血液疾病等全身性疾病的相关信息。因此,视网膜血管图像分割技术研究对视觉威胁性疾病的诊断具有重要意义。

近年来,国内外研究医学图像分割的学者越来越多,提出了很多医学图像分割方法。如 2015 年,Ronneberger等<sup>[1]</sup>基于全卷积神经网络提出了 U 型网络(unity network,U-Net),是生物医学图像分割领域的开创性成果,被广泛沿用至今,在细胞图像分割、肺部图像分割、脑核磁共振成像(magnetic resonance imaging,MRI)分割等领域取得了突破性进展。在此基础上,Guo 等<sup>[2]</sup>提出了基于 U-Net 结构获得视网膜血管的局部特征,并完成了端到端的视网膜血管分割任务,针对卷积层提出正则化方法随机失活块(DropBlock)代替传统卷积随机失活层(Dropout),使用结构化 DropBlock 来正则化 U-Net 结构。狄巨星等<sup>[3]</sup>提出了基于对称式残差 U-Net 结构用于视网膜血管分割,该模型保留了 U-Net 对称式的编码器-解码器结构,并将改进后的残差块进行融合,利用残差块增强网络获取特征的能力。徐婷宜等<sup>[4]</sup>提出了基于改进 U-Net 的视网膜血管分割模型,使用残差结构替换 U-Net 的原始卷积模块,同时在下采样中引入了注意力机制,提高了细小血管的分割率。陈林等<sup>[5]</sup>提出了基于残差与卷积模块的注意力机制混合编码器-编码器结构的视网膜血管分割模型,该模型提高了细小血管的分割效果。原忠虎等<sup>[6]</sup>提出以密集连接网络(densely connected convolution networks,DenseNet)为基础网络,在编码器部分通过密集连接方式进行特征提取,采用空洞卷积代替标准卷积来增大感受野。

上述 U-Net 及其改进模型已被广泛应用于视网膜血管分割领域,但仍存在许多局限性,如大多数模型没有考虑复杂的血管结构特征,只提取了简单的血管特征,导致存在微血管分割精度低与病灶区域误分割的现象。为解决这一问题,提出结合密集空洞卷积(dense atrous convolution,DAC)模块与残差挤压激励机制(residual squeeze and excitation,RSE)模块的视网膜血管分割模型(DACRSE-Unet),可以更好地保留视网膜主血管和毛细血管的局部和全局信息。

## 1  模型结构

### 1.1  模型总体架构

模型总体框架结构如图 1 所示。由图 1 可知,该模型保留了 3 层 U-Net 的基本结构,为了防止出现梯度消失和网络退化等问题,并有效防止网络的过拟合、提高网络训练速度,设计了 RSE 模块代替原 U-Net 中的卷积层,使用 2×2 最大池化层进行下采样操作。为了捕获多尺度的血管特征信息,在编码器与解码器中间引入了 DAC 模块来增大网络感受野,并充分提取上下文的有效信息。通过 2×2 转置卷积进行上采样操作,将图像尺寸恢复到与输入图像一致,最后由解码层输出,传送至带有 Sigmoid 激活函数的 1×1 卷积,并输出最终预测的视网膜血管分割图像。

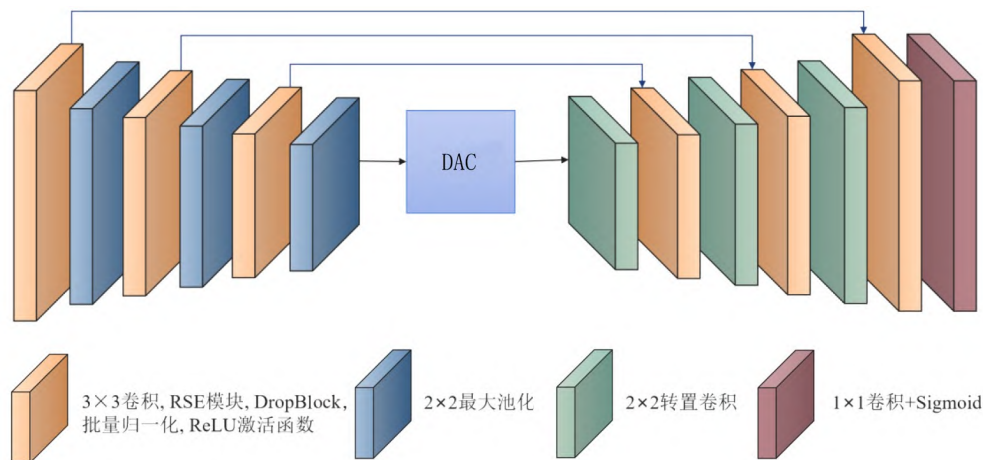


图 1  DACRSE-Unet 总体框架结构  
Fig.1  DACRSE-Unet overall framework structure

### 1.2  改进残差模块

浅层网络可能会限制模型提取所需血管特征的能力,因此通过建立更深层次的神经网络可以学习到更

复杂的血管特征。为了解决增加网络层的数量可能出现的阻碍训练、出现网络退化等问题,He 等<sup>[7]</sup>提出了残差网络结构(residual network, ResNet),在计算机视觉领域产生了广泛影响。因此,实验采用改进残差模块,结构如图 2 所示。由图 2(a)可知,U-Net 原始卷积是通过  $3 \times 3$  卷积层、修正线性单元(rectified linear unit, ReLU)激活函数、批量归一化组合而成的残差块,在此基础上提出了 1 个预激活残差块(见图 2(b))。由图 2(b)可知,这个预激活残差块替换了 U-Net 原始卷积,并将这个修改后的结构作为“主干”。

Ghiasi 等<sup>[8]</sup>提出了具有失活变体的 DropBlock,并证明了其在卷积网络中的有效性;Guo 等<sup>[2]</sup>提出了结构化随机失活 U-Net(structured dropout U-net, SD-Unet)模型,证明 DropBlock 可以有效防止全卷积网络(fully convolutional networks, FCNs)中的过拟合问题。由图 2(c)可知,受上述研究启发,在预激活残差块中引入了 DropBlock,为了使输入和输出通道的数量相同,将采用  $1 \times 1$  卷积来压缩或扩展通道的数量。

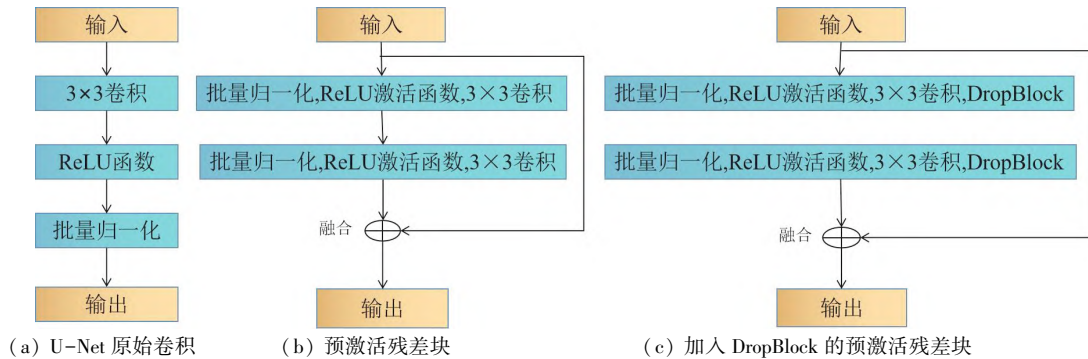


图 2 改进残差模块

Fig.2 Improved residual block

### 1.3 残差挤压激励模块

Hu 等<sup>[9]</sup>提出了挤压激励模块(squeeze and excitation module, SE),该模块结构如图 3 所示。SE 可以利用特征通道之间的相互依赖性,对特征的权重进行调节,使网络强调有效特征并抑制无效特征。由图 3 可知,SE 在进行卷积操作之后会对特征图进行通道特征调整,具体包括压缩、激励、通道加权 3 个步骤。




图 3 SE 结构

Fig.3 SE structure

首先是压缩操作  $F_{sq}(\cdot)$ 。待输入特征图  $X$  的维度为  $H \times W \times C$ ,  $H$ 、 $W$ 、 $C$  分别代表高度、宽度、通道数;通过卷积算子  $F_{tr}$  转换映射到特征图  $U (X \in R^{H \times W \times C})$ ,再利用全局平均池化来实现  $F_{sq}(\cdot)$ 。设统计量  $z \in R^c$  是通过将  $U$  缩小到空间维度  $H \times W$  生成的,  $u_c$  为空间维度  $H \times W$ 。因此,  $z$  的第  $c$  个元素  $z_c$  的计算公式为

$$z_c = F_{sq}(u_c) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W u_c(i, j). \quad (1)$$

其次是激励操作  $F_{ex}(\cdot, W)$ 。将压缩操作得到的  $1 \times 1 \times C$  维度融入全连接层,预测各个通道的重要程度,然后再通过激励到前面特征图的对应通道上进行操作;同时,通过 1 个带有 Sigmoid 激活函数与简单的门控机制来实现,其计算公式为

$$s = F_{ex}(z, W) = \sigma(g(z, W)) = \sigma(W_2 \delta(W_1 z)), \quad (2)$$

其中,  $s$  为门控单元;  $\sigma$  表示 Sigmoid 激活函数;  $\delta$  表示 ReLU 激活函数;  $W_1$  和  $W_2$  分别为 2 个全连接层(full connection, FC)的权重,  $W_1 \in R^{\frac{C}{r} \times C}$ ,  $W_2 \in R^{C \times \frac{C}{r}}$ 。通过 1 个降维层(降维率为  $r$ )、1 个 ReLU 激活函数、1 个维度增加层变换输出  $U$  的通道维度。

最后是通道加权  $F_{scale}(\cdot, \cdot)$ 。将前面的值和特征图重新加权,缩放  $U$  来获得特征图的最终输出:

$$\tilde{X} = F_{scale}(u_c, s_c) = s_c u_c, \quad (3)$$



其中,  $\tilde{X} = [\tilde{x}_1, \tilde{x}_2, \dots, \tilde{x}_c]$ ;  $s_c$  是门控单元  $s$  中的标量;  $F_{\text{scale}}(u_c, s_c)$  是标量  $s_c$  和特征映射  $u_c \in R^{H \times W}$  之间的通道级 (channel-wise) 乘法。结合改进残差网络和 SE 的优点, 并受到卷积注意力模块在分类和检测中成功应用的启发, 将 SE 集成到加入 DropBlock 的预激活残差块中 (见图 2(c)), 提出残差挤压激励 (RSE) 模块, 结构如图 4 所示。由图 4 可知, 该模块主要包含批量归一化、ReLU 激活函数、 $3 \times 3$  卷积、DropBlock 和 SE。

#### 1.4 密集空洞卷积模块

空洞卷积在语义分割、目标检测、图像处理等许多任务中有着广泛应用。在深度学习算法中, 通常利用池化层和卷积层来增加特征图像的感受野, 减少特征图像的大小。由于特征图像在收缩和放大的过程中精度会降低, 因此采用空洞卷积可以增加图像的感受野, 并保持特征图的大小, 还能减少网络的计算。空洞卷积的扩张率可以设置为不同值, 实现从不同感受野获得多尺度的特征信息, 公式如下所示:

$$f(i) = \sum_k x[i + r * k]w[k], \quad (4)$$

其中,  $f(i)$  为空洞卷积求和的值;  $r$  和  $k$  分别为扩张率和卷积核大小; 特征映射输入  $x$  通过  $w$  转换得到特征图  $f$  输出。当设置卷积核为 3 时, 不同扩张率空洞卷积对比如图 5 所示。由图 5 可知, 随着扩张率的增加, 感受野会逐渐增大。




图 5 具有不同扩张率空洞卷积

Fig.5 Atrous convolutions with different expansion rates

为了灵活增大模型的感受野, 在空洞卷积基础上引入了 DAC 模块, 该模块结构如图 6 所示。通过使用不同的扩张率来增大感受野, 可捕获不同尺度的上下文信息来获得局部或全局的信息, 空洞卷积通过使用不同的扩张率  $r_k$  来实现 DAC 模块输出图像, 感受野  $D$  计算公式如下所示:

$$D = \sum_K f_{r_k}(k), \quad (5)$$

其中,  $K$  为不同 DAC 卷积率的求和;  $k$  为卷积核大小;  $f_{r_k}(k)$  为不同 DAC 的值。

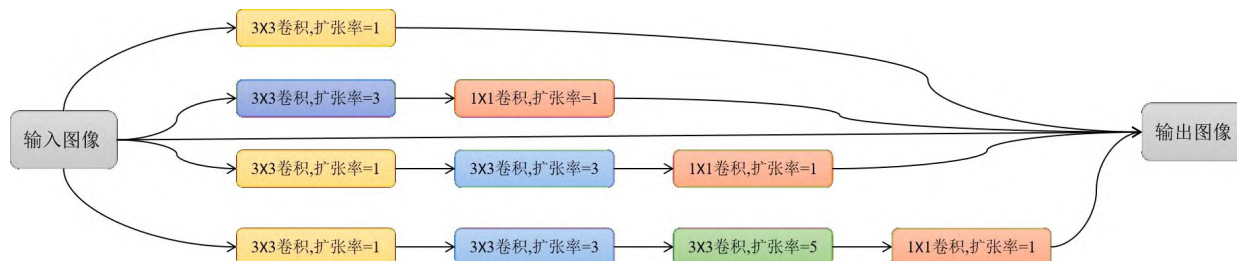


图 6 密集空洞卷积模块

Fig.6 Dense atrous convolutional module

由图 6 可知, DAC 模块有 4 个级联分支, 在每个分支中空洞卷积的数量是由上到下逐个增加的, 经式 (5) 计算, 对应的感受野分别是 3、7、9、19; 同时, 每个分支最后都使用 1 个  $1 \times 1$  卷积对特征图进行线性激活, 最后与原始输入特征图相加; 该思路来源于 ResNet 中的残差连接, 能有效防止梯度爆炸和消失。DAC 模块

与下采样相比,在不减少空间分辨率损失的情况下,仍然可以很好地扩大感受野,获取上下文的特征信息,并对视网膜细小血管进行精准分割<sup>[10]</sup>。

## 2 实验与结果

### 2.1 数据与预处理

在 2 个公开数据集,用于血管提取的数字视网膜图像(digital retinal images for vessel extraction,DRIVE)数据集<sup>[11]</sup>和视网膜结构分析(structured analysis of the retina,STARE)数据集<sup>[12]</sup>上验证 DACRSE-Unet 模型的有效性。DRIVE 数据集来自荷兰的糖尿病病变筛查项目,其中包括 20 幅训练图像和 20 幅测试图像,每幅图像分辨率为 565 像素×584 像素。STARE 数据集由 20 幅分辨率为 700 像素×605 像素视网膜图像组成,由于在该数据集中官方未划分训练集和测试集,因此自动划分前 10 幅图像作为测试集,后 10 幅图像作为训练集。

由于 DRIVE 和 STARE 公开数据集上图片数据较少,为提高模型的泛化能力和鲁棒性,分别对这 2 个数据集进行如下数据增强处理:1)对数据集随机旋转 360 度;2)颜色变换;3)添加高斯噪声;4)水平和垂直翻转。上述每个处理都会把原始图像从 1 幅扩增到 4 幅,将这 2 个数据集中的训练集分别都扩增到 236 幅图像,测试集分别为 20 幅和 10 幅图像;其中,验证集采用交叉验证方法划分,占训练集的 10%。同时,对 DRIVE 和 STARE 数据集的原始像素进行裁剪,DRIVE 数据集调整为 592 像素×592 像素,STARE 数据集调整为 704 像素×704 像素,周围像素都使用 0 进行填充。

### 2.2 实验设置

实验在 CPU 为 Inter(R) Core(TM) i7-12700F、内存为 16 GB、显卡为 NVIDIA GeForce GTX 3060 GPU 12 GB 的环境下进行,采用 Windows 10 操作系统。DACRSE-Unet 模型在 Keras 框架上进行实验,批量大小为 8,训练总轮次为 50,采用交叉熵损失函数和 Adam 模型进行优化,初始学习率设置为 0.000 1。

### 2.3 评价指标

为了定量评估 DACRSE-Unet 模型,采用准确率、灵敏度、特异性、F1 分数作为评价指标。为了进一步评估模型性能,还采用接受者操作特性曲线(receiver operating characteristic curve,ROC)的曲线下面积(area under ROC curve,AUC)来评估。各评价指标计算公式如下所示:

$$P_{Acc} = \frac{N_{TP} + N_{TN}}{N_{TN} + N_{TP} + N_{FN} + N_{FP}}, \quad (6)$$

$$P_{Se} = \frac{N_{TP}}{N_{TP} + N_{FP}}, \quad (7)$$

$$P_{Sp} = \frac{N_{TN}}{N_{TN} + N_{FP}}, \quad (8)$$

$$P_{F1} = \frac{N_{2TP}}{N_{2TP} + N_{FN} + N_{FP}}。 \quad (9)$$

其中, $N_{TP}$ 为被正确分割的血管像素个数; $N_{FP}$ 为被分割错误的血管像素个数; $N_{FN}$ 为被分割错误的背景像素个数; $N_{TN}$ 为被正确分割的背景像素个数; $N_{2TP} = 2 \times N_{TP}$ ;  $P_{Acc}$ 、 $P_{Se}$ 、 $P_{Sp}$ 、 $P_{F1}$ 分别为准确率、敏感度、特异性和 F1 分数。

其中, $P_{F1}$ 为精确率与召回率之间的调和平均值,用于表征模型的分割结果与金标准(即医学专家手动分割结果)之间的相似程度,其值介于 0~1 之间;越接近 1,表明模型的分割效果越好。ROC 曲线是医学图像分割任务常用的评价指标,ROC 曲线下面积 AUC 的值越接近 1,说明模型的分割效果越好。

### 2.4 模型性能对比

为了证实 DACRSE-Unet 模型对 U-Net 改进的有效性,将其与 U-Net、SD-Unet、基于 U 型网络的多模块连接(multi-module concatenation based on U-Net,MC-Unet)这 3 个模型进行实验对比。分别在 DRIVE 和 STARE 数据集上测试了  $P_{Acc}$ 、 $P_{Se}$ 、 $P_{Sp}$ 、 $P_{F1}$ 、AUC 数值,实验结果如表 1 所示。由表 1 可知,DACRSE-Unet 模型各个指标均为最优;与目前在视网膜血管分割领域表现较好的 MC-Unet 模型相比,除  $P_{Sp}$  外, $P_{Acc}$ 、 $P_{Se}$ 、 $P_{F1}$ 、AUC 值均有所提高,证实了 DACRSE-Unet 模型是有效的视网膜血管分割模型。

### 2.5 整体分割效果对比

将 DACRSE-Unet 模型与 U-Net、SD-Unet、MC-Unet 这 3 种视网膜血管分割模型在 DRIVE 和 STARE 数

数据集上进行视网膜血管分割实验,结果如图 7 所示。由图 7 可知,U-Net 模型作为视网膜血管分割网络中的经典模型,仅能分割出主干血管,且在血管交叉处容易出现误分割和血管断裂等问题;SD-Unet 模型中使用 DropBlock 代替 Dropout 层,相比 U-Net 在分割效果上有所提高,但在细小血管分割时仍会出现误分割的现象;MC-Unet 模型将空间注意力、DAC 模块和多核池化模块结合,在一定程度上获取了局部和全局信息,但仍存在血管分割断裂和细小血管不易分割的缺陷。而 DACRSE-Unet 模型不仅能够精准地分割出细小血管,且其分割效果与医学专家手动分割的效果(即图 7(b)所示的“金标准”)比较接近;另外,该模型还能够很好地保留血管连续性和完整性,进而实现细小血管的高精度分割。

表 1  模型的性能对比  
Tab.1  Performance comparison of models

数据集	模型	$P_{Acc}$	$P_{Se}$	$P_{Sp}$	AUC	$P_{F1}$
DRIVE	U-Net	0.960 4	0.601 4	<b>0.994 8</b>	0.971 1	0.726 6
	SD-Unet	0.968 2	0.791 3	0.985 2	0.984 3	0.813 6
	MC-Unet	0.968 4	0.781 0	0.985 8	0.983 8	0.813 3
	DACRSE-Unet	<b>0.969 2</b>	<b>0.822 6</b>	0.983 3	<b>0.986 9</b>	<b>0.824 0</b>
STARE	U-Net	0.966 4	0.643 8	0.992 7	0.976 4	0.742 8
	SD-Unet	0.970 9	0.869 5	0.979 2	0.989 3	0.818 4
	MC-Unet	0.976 6	0.770 8	<b>0.993 4</b>	0.992 3	0.832 5
	DACRSE-Unet	0.983 0	0.877 9	0.991 6	<b>0.996 4</b>	<b>0.886 2</b>




图 7  不同模型的整体分割效果  
Fig.7  Segmentation effects of different models

2.6  细节分割效果对比

为了更好地突出 DACRSE-Unet 模型的性能与优势,将其进一步与 U-Net、SD-Unet、MC-Unet 这 3 种视网膜血管分割模型进行局部分割细节对比,结果如图 8 和图 9 所示。由图 8 和图 9 可知,U-Net 模型在细节分割上只分割出主干血管,有些细小血管分割存在没有精准分割、断裂、误分割等现象,分割精度较低;SD-Unet 模型相较于 U-Net 模型,对细小血管分割的准确率有一定提高,但仍存在细小血管误分割的问题;MC-Unet 模型相比前 2 种模型,对细小血管分割的准确率有所提高,但仍存在血管断裂的问题。而 DACRSE-Unet 模型不仅可以对视网膜主干血管进行精准分割,还可以精准地分割细小血管,保证血管的连续性和完整性;另外,该模型的分割效果与医学专家手动分割的标准(即图 8(b)和图 9(b)所示的“金标准”)比较接近。






图 8 DRIVE 数据集上的细节分割效果  
Fig.8 Detailed segmentation effects of the DRIVE dataset

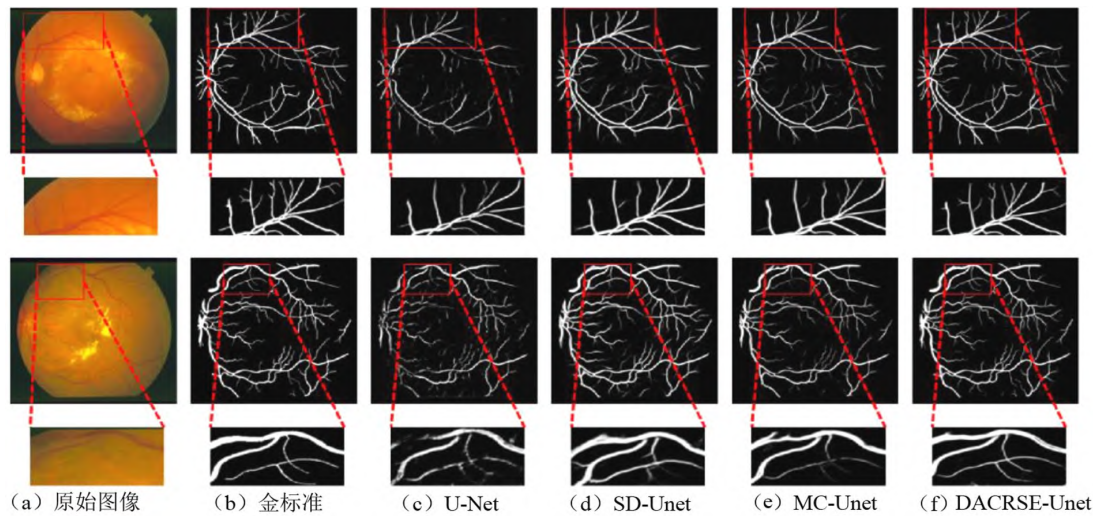


图 9 STARE 数据集上的细节分割效果  
Fig.9 Detail segmentation effects of the STARE dataset

2.7 消融实验

为了进一步验证 DACRSE-UNet 模型中各个模块的有效性,分别在 DRIVE 和 STARE 数据集上进行消融实验,结果如表 2 所示。其中,D1 代表 U-Net 模型,D2 为在 D1 基础上加入 DropBlock,D3 为在 D2 基础上加入残差模块,D4 为在 D3 基础上加入 SE,D5 为完整的 DACRSE-UNet 模型。

表 2 消融实验结果  
Tab.2 Results of ablation experiment

数据集	模型	$P_{Acc}$	$P_{Se}$	$P_{Sp}$	AUC	$P_{F1}$
DRIVE	D1	0.960 4	0.601 4	<b>0.994 8</b>	0.971 1	0.726 6
	D2	0.968 2	0.791 3	0.985 2	0.984 3	0.813 6
	D3	0.968 6	0.769 9	0.987 7	0.984 5	0.811 1
	D4	0.969 1	0.783 9	0.986 8	0.984 7	0.816 1
	D5	<b>0.969 2</b>	<b>0.822 6</b>	0.983 3	<b>0.986 9</b>	<b>0.824 0</b>
STARE	D1	0.966 4	0.643 8	<b>0.992 7</b>	0.976 4	0.742 8
	D2	0.970 9	0.869 5	0.979 2	0.989 3	0.818 4
	D3	0.973 3	<b>0.921 6</b>	0.977 5	0.993 9	0.838 7
	D4	0.980 4	0.875 5	0.989 0	0.995 2	0.871 0
	D5	<b>0.983 0</b>	0.877 9	0.991 6	<b>0.996 4</b>	<b>0.886 2</b>

由表2可知,D1在视网膜血管分割方面有不错的效果;D2与D1比较,除了 $P_{Sp}$ 外,其他指标均有提升;D3与D2比较,加入了残差模块, $P_{Acc}$ 、AUC等值都有所提升,说明加入的残差模块可以有效提取特征;D4与D3比较,加入SE,该模块可以强调有用特征并抑制无用特征,以提高微小血管的分割效果, $P_{Acc}$ 、AUC、 $P_{F1}$ 值均有所提升;D5是完整DACRSE-Unet模型,在D4基础上加入DAC模块来获取微小血管的多尺度信息,除了在DRIVE和STARE数据集上的 $P_{Sp}$ 与在STARE数据集的 $P_{Se}$ 略低,其他指标均较高,说明该模型可以通过RSE模块提取有效特征、抑制无用特征,并通过引入DAC模块来增大感受野,从而实现对细小血管的高精度分割。

### 3 结论

高精度分割视网膜血管是医生诊断青光眼、心血管疾病等的重要环节,但在血管的外围区域,以往基于U-Net模型的分割方法未能显著保留对比度低的细小血管。为解决这一问题,提出结合密集空洞卷积(DAC)模块与残差挤压激励(RSE)模块的视网膜血管分割模型(DACRSE-Unet)来提取特征;其中,残差网络可以避免出现梯度消失和网络退化的问题,挤压激励(SE)机制可以捕获重要特征而抑制不重要特征,在模型中添加DAC模块可以获得丰富的血管特征信息。实验结果证实了DACRSE-Unet模型的优越性,与其他模型进行比较,该模型在DRIVE和STARE数据集上的准确率和灵敏度最为显著,分别为0.9692、0.8226和0.9830、0.8779,说明该模型能够有效解决视网膜血管分割未能保留对比度低的血管信息以及分割效率不高的问题。但DACRSE-Unet模型对低对比度下的血管和含有较多病理信息的图像仍会产生少数血管断裂和误分割问题,下一步实验将探索更好的视网膜图像预处理方法,并进一步提高模型的分割性能。

### 参考文献:

- [1] RONNEBERGER O, FISCHER P, BROX T. U-Net: convolutional networks for biomedical image segmentation [C]//2015 Medical Image Computing and Computer-Assisted Intervention. Munich: Springer International Publishing, 2015: 234-241.
- [2] GUO C, SZEMENYEI M, PEIZ Y, et al. SD-UNet: a structured dropout U-Net for retinal vessel segmentation [C]//2019 IEEE 19th International Conference on Bioinformatics and Bioengineering. Athens: IEEE Computer Society, 2019: 439-444.
- [3] 狄巨星, 刘双和. 基于改进残差U-Net的视网膜血管分割算法[J]. 信息技术与信息化, 2022, 271(10): 87-90.
- [4] 徐婷宜, 朱家明, 宋泉. 基于改进U-Net的视网膜血管分割[J]. 计算机仿真, 2022, 39(11): 323-327.
- [5] 陈林, 陈亚军, 沈锐. 基于残差卷积注意力网络的视网膜血管分割算法[J]. 内江师范学院学报, 2021, 36(2): 49-55.
- [6] 原忠虎, 雷莹, 韩晓微. 基于密集空洞卷积的注意力机制视网膜血管分割方法[J]. 沈阳大学学报(自然科学版), 2022, 34(4): 274-282.
- [7] HE K, ZHANG X, REN S, et al. Identity mappings in deep residual networks [C]//2016 Computer Vision ECCV 2016: 14th European Conference. Amsterdam: Springer International Publishing, 2016: 630-645.
- [8] GHIASI G, LIN T Y, LE Q V. A regularization method for convolutional networks [C]//2018 2nd International Conference on Neural Information Processing Systems. Dutchess County: Curran Associates Inc., 2018: 10727-10737.
- [9] HU J, SHEN L, SUN G. Squeeze-and-excitation networks [C]//2018 IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City: IEEE, 2018: 7132-7141.
- [10] GU Z, CHENG J, FU H, et al. CE-Net: context encoder network for 2d medical image segmentation [J]. IEEE Transactions on Medical Imaging, 2019, 38(10): 2281-2292.
- [11] STAAL J, ABRAMOFF M D, NIEMEIJER M, et al. Ridge-based vessel segmentation in color images of the retina [J]. IEEE Transactions on Medical Imaging, 2004, 23(4): 501-509.
- [12] HOOVER A D, KOUZNETSOVA V, GOLDBAUM M. Locating blood vessels in retinal images by piecewise threshold probing of a matched filter response [J]. IEEE Transactions on Medical Imaging, 2000, 19(3): 203-210.

责任编辑: 郑玥雷